BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THỰC PHẨM TP. HCM

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC

HỌC PHẦN: CÔNG NGHỆ DỮ LIỆU LỚN (BIG DATA)

"XÂY DỰNG DATA PIPELINE THU THẬP, XỬ LÝ PHÂN TÁN VÀ PHÂN TÍCH DỮ LIỆU THỊ TRƯỜNG CHUYỂN NHƯỢNG BÓNG ĐÁ QUỐC TẾ"

GVHD: ThS. Huỳnh Thái Học

SINH VIÊN THỰC HIỆN: **1. Đặng Duy Lợi - MSSV: 2001230479 - Lớp: 14DHTH06**

2. Chu Văn Quốc Trung - MSSV: 2001231010 - Lớp: 14DHTH06

3. Nguyễn Thế Quang - MSSV: 20012307010 - Lớp: 14DHTH06

NGÀNH ĐÀO TẠO: Công nghệ Thông tin / Khoa học Dữ liệu

TP. HỒ CHÍ MINH, tháng 10 năm 2026

BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THỰC PHẨM TP. HCM

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC

HỌC PHẦN: CÔNG NGHỆ DỮ LIỆU LỚN (BIG DATA)

"XÂY DỰNG DATA PIPELINE THU THẬP, XỬ LÝ PHÂN TÁN VÀ PHÂN TÍCH DỮ LIỆU THỊ TRƯỜNG CHUYỂN NHƯỢNG BÓNG ĐÁ QUỐC TẾ"

GVHD:	ThS. Huỳnh Thái Học
SINH VIÊN THỰC HIỆN:	**1. Đặng Duy Lợi - MSSV: 2001230479 - Lớp: 14DHTH06**
	2. Chu Văn Quốc Trung - MSSV: 2001231010 - Lớp: 14DHTH06
	3. Nguyễn Thế Quang - MSSV: 20012307010 - Lớp: 14DHTH06
NGÀNH ĐÀO TẠO:	Công nghệ Thông tin / Khoa học Dữ liệu
LIÊN KẾT REPO:	https://github.com/takachi15/transfermarkt-bigdata-analytics
MÃ NGUỒN ĐÍNH KÈM:	Thư mục Source_Code/ (Kèm CHAY_WEB.bat & CHAY_PIPELINE.bat)

TP. HỒ CHÍ MINH, tháng 10 năm 2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan đây là công trình nghiên cứu và thực nghiệm của riêng nhóm chúng tôi dưới sự hướng dẫn của ThS. Huỳnh Thái Học – Giảng viên phụ trách học phần. Các số liệu, bảng biểu, hình ảnh minh chứng và kết quả phân tích nêu trong Báo cáo Đồ án là hoàn toàn trung thực, được tính toán trực tiếp từ hệ thống mã nguồn thực tế và chưa từng được công bố trong bất kỳ công trình nào khác.

Chúng tôi xin cam đoan rằng mọi sự giúp đỡ cho việc thực hiện Đồ án này đã được cảm ơn chân thành và các thông tin, tài liệu trích dẫn trong Báo cáo đều đã được chỉ rõ nguồn gốc theo chuẩn học thuật.

TP. Hồ Chí Minh, ngày 27 tháng 10 năm 2026
Sinh viên thực hiện
(Ký và ghi rõ họ tên)

1. Đặng Duy Lợi
2. Chu Văn Quốc Trung
3. Nguyễn Thế Quang

LỜI CẢM ƠN

Để hoàn thành đồ án môn học Công nghệ Dữ liệu lớn (Big Data Technologies), nhóm chúng tôi xin bày tỏ lòng biết ơn sâu sắc đến Ban Giám hiệu Trường Đại học Công nghiệp Thực phẩm TP.HCM (nay là Trường Đại học Công Thương TP.HCM), cùng toàn thể Quý Thầy/Cô Khoa Công nghệ Thông tin đã tạo mọi điều kiện thuận lợi và truyền đạt những nền tảng kiến thức quý báu cho chúng tôi trong suốt quá trình học tập.

Đặc biệt, nhóm xin gửi lời tri ân chân thành nhất đến ThS. Huỳnh Thái Học – Giảng viên hướng dẫn môn học, đã tận tình định hướng đề tài, giải đáp các vướng mắc kỹ thuật và chỉ dẫn phương pháp triển khai các hệ thống tính toán phân tán phức tạp như Hadoop HDFS, Apache Spark, Kafka và Airflow.

Mặc dù đã nỗ lực hết mình để hoàn thiện hệ thống và tài liệu báo cáo, song do tính chất chuyên sâu của công nghệ Big Data, đồ án chắc chắn không tránh khỏi những thiếu sót nhất định. Nhóm chúng tôi rất mong nhận được những đóng góp quý báu từ Quý Thầy/Cô để đồ án ngày càng hoàn thiện hơn.

Nhóm sinh viên thực hiện đồ án

Đặng Duy Lợi – Chu Văn Quốc Trung – Nguyễn Thế Quang

TÓM TẮT ĐỒ ÁN

Đồ án tập trung nghiên cứu và xây dựng một hệ thống Data Pipeline hoàn chỉnh phục vụ bài toán thực tế: thu thập, lưu trữ phân tán, xử lý tính toán song song, học máy và trực quan hóa dữ liệu thị trường chuyển nhượng bóng đá quốc tế dựa trên bộ dữ liệu Transfermarkt Football Dataset quy mô 12 bảng CSV (~870 MB).

Về mặt công nghệ, hệ thống tích hợp đồng bộ các trụ cột Big Data hàng đầu hiện nay:

1. **Hadoop HDFS 3.x:** Đóng vai trò Data Lake lưu trữ phân tán an toàn toàn bộ 12 tệp dữ liệu thô tại cổng 9870.
2. **Apache Spark 3.x / PySpark 4.2:** Động cơ xử lý phân tán trong bộ nhớ, thực hiện ETL làm sạch 50.149 bản ghi thô xuống 40.756 bản ghi sạch và thực thi 4 câu lệnh Spark SQL đa chiều.
3. **Spark MLlib:** Áp dụng thuật toán phân cụm K-Means với Silhouette Score tối ưu (k=3 đạt 0.6429) để chia cầu thủ thành 3 đẳng cấp thị trường; đồng thời xây dựng Pipeline Random Forest Regressor với biến đổi thang log đạt độ chính xác R^2 = 84.68% và RMSE = 0.5942.
4. **Apache Kafka 3.x:** Xử lý luồng sự kiện thời gian thực (topic 'football_transfers' cổng 9092) phát sóng và bóc tách các thương vụ chuyển nhượng trực tiếp.
5. **Apache Airflow 2.10:** Điều phối tự động hóa toàn bộ chu trình qua DAG 7 task tuần tự chạy trên Docker Compose đạt 100% trạng thái 'success'.
6. **Serving Data Mart & Streamlit Dashboard:** Lưu trữ vào CSDL quan hệ football_analytics.db và trực quan hóa tương tác qua Web Dashboard 6 trang.

Từ khóa: Big Data, Hadoop HDFS, PySpark, Spark SQL, Spark MLlib, Apache Kafka, Apache Airflow, Machine Learning, Streamlit Dashboard.

MỤC LỤC

LỜI CAM ĐOAN 3
LỜI CẢM ƠN 4
TÓM TẮT ĐỒ ÁN 5
DANH MỤC CÁC TỪ VIẾT TẮT 9
DANH MỤC CÁC BẢNG BIỂU 9
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ 10
CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN VÀ NGUỒN DỮ LIỆU 13
1.1. Bối cảnh thị trường bóng đá và bài toán thực tế đặt ra 13
1.2. Mục tiêu nghiên cứu và phạm vi đề tài 13
1.3. Nguồn dữ liệu, định dạng và quy mô hệ thống 14
1.4. Cấu trúc Schema bảng dữ liệu trung tâm (players.csv) 15
1.4.1. Nhóm thuộc tính định danh và nhân khẩu học 16
1.4.2. Nhóm thuộc tính thể chất và kỹ thuật thi đấu 16
1.4.3. Biến mục tiêu định giá: market_value_in_eur 17
CHƯƠNG 2: KIẾN TRÚC HỆ THỐNG VÀ CÔNG NGHỆ BIG DATA 18
2.1. Kiến trúc phân tầng 5 lớp (Lambda Architecture) 18
2.2. Hệ thống tệp lưu trữ phân tán Hadoop HDFS 18
2.3. Động cơ tính toán phân tán Apache Spark & Spark SQL 18
2.4. Message Broker xử lý luồng sự kiện Apache Kafka 19
2.5. Hệ thống điều phối luồng công việc Apache Airflow 19
2.6. Cơ sở dữ liệu phục vụ và Web Dashboard tương tác 19

CHƯƠNG 3: THIẾT KẾ VÀ TRIỂN KHAI BIG DATA PIPELINE 20
3.1. Chuyển nạp dữ liệu vào Hadoop HDFS Data Lake 20
3.2. PySpark ETL: Đọc HDFS, làm sạch và Feature Engineering 20
3.3. Xử lý luồng thời gian thực với Apache Kafka 22
3.4. Tự động hóa điều phối Workflow với Apache Airflow 2.10 23
3.5. Xây dựng CSDL Serving Data Mart (football_analytics.db) 25
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH CHUYÊN SÂU 26
4.1. Phân tích thống kê 4 chiều với Spark SQL và Insights 26
4.1.1. Truy vấn 1: Top 10 cầu thủ có giá trị chuyển nhượng cao nhất thế giới 26
4.1.2. Truy vấn 2: Thống kê tương quan giữa vị trí thi đấu, thể hình và định giá .27
4.1.3. Truy vấn 3: Phân tích phân bổ ngân sách thị trường theo giải đấu.....27
4.1.4. Truy vấn 4: Đánh giá độ tuổi trung bình và chu kỳ đỉnh cao phong độ 27
4.2. Học máy gom cụm đẳng cấp cầu thủ với Spark MLlib K-Means 28
4.3. Học máy dự đoán giá trị chuyển nhượng với Random Forest 29
4.4. Trực quan hóa tương tác trên Web Dashboard Big Data 30
4.5. Bằng chứng giao diện Web Dashboard sử dụng trực tiếp đầu ra từ Pipeline 38
4.6. Bảng ma trận đối chiếu chứng minh tính tái hiện toàn diện (Traceability Matrix) 40
CHƯƠNG 5: HỒ SƠ NỘP, NHẬT KÝ THỰC HIỆN VÀ ĐÓNG GÓP THÀNH VIÊN 42
5.1. Hồ sơ nộp đồ án và Liên kết Repository mã nguồn 42
5.2. Nhật ký mốc tiến độ thực hiện đồ án theo tuần 42

5.3. Bảng tổng hợp lỗi kỹ thuật và giải pháp khắc phục triệt để.....43
5.4. Bảng tổng hợp lịch sử Commit Git tiêu biểu theo các mốc tiến độ.....44
5.5. Bảng phân công chi tiết và Tỷ lệ đóng góp của 3 thành viên.....45
5.6. Tuyên bố tuân thủ an toàn bảo mật thông tin.....46
CHƯƠNG 6: KẾT LUẬN VÀ KIẾN NGHỊ.....47
6.1. Đánh giá kết quả đạt được.....47
6.2. Hạn chế của đề tài.....47
6.3. Kiến nghị và hướng nghiên cứu tiếp theo.....47
TÀI LIỆU THAM KHẢO.....49
PHỤ LỤC: HƯỚNG DẪN CÀI ĐẶT VÀ KHỞI CHẠY HỆ THỐNG.....50

DANH MỤC CÁC TỪ VIẾT TẮT

Từ viết tắt	Tên tiếng Anh đầy đủ	Ý nghĩa / Giải thích chuyên môn
HDFS	Hadoop Distributed File System	Hệ thống tập tin phân tán Hadoop
ETL	Extract, Transform, Load	Quy trình trích xuất, biến đổi và nạp dữ liệu
MLlib	Machine Learning Library (Spark)	Thư viện học máy phân tán trên Apache Spark
DAG	Directed Acyclic Graph	Đồ thị có hướng không chu trình (Airflow Workflow)
R^2	R-squared (Coefficient of Det.)	Hệ số xác định đánh giá độ chính xác mô hình hồi quy
RMSE	Root Mean Squared Error	Căn bậc hai của sai số bình phương trung bình
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
CSV	Comma-Separated Values	Định dạng tệp dữ liệu phân tách bởi dấu phẩy

DANH MỤC CÁC BẢNG BIỂU

Bảng 1.1: Danh mục 12 tệp tin dữ liệu Transfermarkt Football Dataset trong Data Lake 14

Bảng 1.2: Cấu trúc Schema 26 thuộc tính bảng players.csv 15

Bảng 4.1: Bảng xếp hạng Top 10 siêu sao đắt giá nhất thế giới (Spark SQL) 26

Bảng 4.2: Thống kê giá trị và thể hình theo 4 vị trí thi đấu 27

Bảng 4.3: Kết quả phân cụm và đặc trưng 3 phân khúc K-Means 28

Bảng 4.4: Chỉ số đánh giá độ chính xác Random Forest Regressor 30

Bảng 4.5: Bảng đối chiếu minh chứng Web Dashboard sử dụng trực tiếp tệp đầu ra của Data Pipeline 38

Bảng 4.6: Bảng ma trận đối chiếu chứng minh tính tái hiện giữa Báo cáo, Code, Lệnh và Minh chứng 40

Bảng 5.1: Nhật ký mốc tiến độ thực hiện đồ án theo tuần 42

Bảng 5.2: Bảng tổng hợp các lỗi kỹ thuật và giải pháp khắc phục 43

Bảng 5.3: Bảng tổng hợp lịch sử Commit Git tiêu biểu theo các mốc tiến độ dự án 44

Bảng 5.4: Bảng phân công chi tiết và Tỷ lệ đóng góp của 3 thành viên 45

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 3.1: Giao diện HDFS NameNode Web UI cổng 9870 – Thư mục /football_project/ lưu trữ 12 tệp CSV (~870 MB) 20

Hình 3.2: Khám phá Schema 26 cột và dữ liệu mẫu của players.csv trên PySpark DataFrame 21

Hình 3.3: Kết quả thực thi PySpark Data Cleaning – Làm sạch thành công 40.749 bản ghi và lưu trữ dạng Parquet 22

Hình 3.4: Kafka Producer phát sóng sự kiện chuyển nhượng định dạng JSON lên cụm phân tán 22

Hình 3.5: Kafka Consumer lắng nghe và bóc tách dữ liệu giao dịch trực tiếp từ topic football_transfers 23

Hình 3.6: Giao diện Web Dashboard – Giám sát trạng thái hoạt động 5 Containers trong cụm Docker Compose Airflow 2.10 24

Hình 3.7: Giao diện Web Dashboard – Đồ thị trực quan hóa luồng dữ liệu 7 Task tuần tự của Airflow DAG (State: success) 25

Hình 4.1: Giao diện Web Dashboard – Kết quả truy vấn Spark SQL xác định Top siêu sao có giá trị chuyển nhượng cao nhất thế giới 26

Hình 4.2: VS Code Terminal thực thi mô hình phân cụm K-Means MLlib (k=3, Silhouette = 0.6429) 28

Hình 4.3: VS Code Terminal huấn luyện Random Forest Regressor trên 40.756 bản ghi (R^2 = 84.7%) 29

Hình 4.4: Giao diện Streamlit Dashboard – Trang Tổng quan thị trường, Top Navbar phân tán và Bộ lọc niên độ động 32

Hình 4.5: Giao diện Streamlit Dashboard – Trang Bản đồ ứng dụng Big Data & Ma trận phân định 5 tầng kiến trúc 33

Hình 4.6: Giao diện Streamlit Dashboard – Trang Benchmark thực nghiệm hiệu năng quét 3.179.016 dòng (Spark 4.2 vs Pandas) 34

Hình 4.7: Giao diện Streamlit Dashboard – Trang Xu hướng thị trường theo năm & Khảo sát chuyên sâu Year Drill-Down (Dòng tiền 12 tháng, Top bom tấn, Top CLB) 35

Hình 4.8: Giao diện Streamlit Dashboard – Trang Machine Learning dự đoán định giá thời gian thực (Real-time ML Inference với tra cứu đa cầu thủ và khoảng tin cậy 95%) 36

Hình 4.9: Giao diện Streamlit Dashboard – Công cụ Tuyển trạch Săn cầu thủ theo Ngân sách & Tiêu chí (Scouting Engine với phân loại Kèo hời Undervalued) 36

Hình 4.10: Giao diện Streamlit Dashboard – Bảng xếp hạng định giá tích hợp phân trang chuẩn Enterprise và đồng bộ URL query params 37

Hình 4.11: Giao diện Streamlit Dashboard – Trang Giám sát luồng sự kiện Kafka Streaming thời gian thực kết nối cổng 9092 37

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN VÀ NGUỒN DỮ LIỆU

1.1. Bối cảnh thị trường bóng đá và bài toán thực tế đặt ra

Thị trường chuyển nhượng bóng đá chuyên nghiệp toàn cầu là một lĩnh vực kinh tế trị giá hàng chục tỷ Euro mỗi mùa giải. Tuy nhiên, việc định giá cầu thủ và ra quyết định chuyển nhượng từ trước đến nay thường mang tính cảm tính, thiếu cơ sở định lượng, dẫn tới sự bất đối xứng thông tin và rủi ro tài chính rất lớn cho các câu lạc bộ (CLB).

Với sự bùng nổ của dữ liệu thống kê từ chuyên trang Transfermarkt (bao gồm hàng triệu sự kiện trận đấu, lịch sử định giá, thông số thể hình và thành tích thi đấu), việc xây dựng một hệ thống Big Data xử lý phân tán toàn diện là bài toán có tính cấp thiết và giá trị ứng dụng thực tiễn rất cao.

1.2. Mục tiêu nghiên cứu và phạm vi đề tài

Đề tài hướng tới việc xây dựng trọn vẹn một Data Pipeline phân tán giải quyết bài toán Big Data từ đầu đến cuối dưới sự hướng dẫn của ThS. Huỳnh Thái Học:

- **Hạ tầng lưu trữ:** Lưu trữ phân tán Data Lake trên Hadoop HDFS đảm bảo khả năng chịu lỗi và tính sẵn sàng cao cho toàn bộ 12 bảng dữ liệu lịch sử (~870 MB).
- **Xử lý phân tán:** Sử dụng Apache Spark (PySpark) để xử lý dữ liệu quy mô lớn, làm sạch giá trị khuyết thiếu và trích xuất các đặc trưng phái sinh.
- **Học máy phân tán:** Áp dụng Spark MLlib K-Means để phân cụm đẳng cấp và Random Forest Regressor để dự đoán định giá thị trường.
- **Xử lý luồng:** Thu thập và xử lý sự kiện giao dịch chuyển nhượng phát sinh liên tục bằng Apache Kafka.
- **Tự động hóa & UI:** Tự động hóa toàn bộ quy trình bằng Apache Airflow DAG và trực quan hóa tương tác qua Streamlit Web Dashboard.

Giải thích lý do kiến trúc kết hợp Batch & Streaming (Kafka): Đối với kho dữ liệu lịch sử (7.5 triệu bản ghi), hệ thống sử dụng xử lý theo mẻ (Batch Processing) bằng

Hadoop HDFS và Apache Spark để thống kê chuyên sâu và huấn luyện mô hình. Đồng thời, đối với thị trường chuyển nhượng bóng đá liên tục diễn ra các thương vụ đột xuất (Breaking News transfer), hệ thống áp dụng Apache Kafka (Speed Layer) phát sóng sự kiện chuyển nhượng định dạng JSON thời gian thực, cập nhật tức thì vào Serving Data Mart mà không cần phải chạy lại toàn bộ mẻ dữ liệu lịch sử hàng trăm megabyte, đáp ứng chuẩn mực kiến trúc Lambda Architecture.

1.3. Nguồn dữ liệu, định dạng và quy mô hệ thống

Bộ dữ liệu Transfermarkt Football Dataset gồm 12 tệp CSV lưu trữ phân tán trên cụm Hadoop HDFS với tổng dung lượng xấp xỉ 872.5 MB, chứa tổng cộng 7.497.433 bản ghi dữ liệu chi tiết:

Bảng 1.1: Danh mục 12 tệp tin dữ liệu Transfermarkt Football Dataset trong Data Lake

Tên tệp tin CSV	Dung lượng đĩa	Số lượng bản ghi	Mô tả nội dung nghiệp vụ
game_lineups.csv	396.71 MB	3.179.016 dòng	Đội hình ra sân chi tiết từng trận (cầu thủ, vị trí, thẻ phạt)
appearances.csv	189.21 MB	1.894.350 dòng	Thống kê thời lượng thi đấu, bàn thắng, kiến tạo, số phút ra sân
game_events.csv	170.80 MB	1.274.469 dòng	Sự kiện chi tiết trong trận (ghi bàn, thay người, thẻ phạt)
player_valuations.csv	37.81 MB	656.301 dòng	Lịch sử biến động định giá cầu thủ qua các mốc thời gian
games.csv	27.62 MB	88.958 dòng	Thông tin trận đấu, tỷ số, mùa giải, trọng tài, sân vận động
players.csv	18.72 MB	50.149 dòng	Hồ sơ cầu thủ trung

			tâm phục vụ tiền xử lý làm sạch và học máy
transfers.csv	17.27 MB	175.165 dòng	Lịch sử các thương vụ chuyển nhượng và mức phí chính thức
club_games.csv	14.06 MB	177.916 dòng	Thống kê kết quả thi đấu, tỷ lệ bàn thắng/thua của từng CLB
clubs.csv	0.20 MB	796 dòng	Danh mục câu lạc bộ chuyên nghiệp trên toàn thế giới
national_teams.csv	0.03 MB	124 dòng	Danh sách đội tuyển quốc gia
countries.csv	0.01 MB	124 dòng	Danh mục quốc gia, liên đoàn và vùng lãnh thổ
competitions.csv	0.01 MB	65 dòng	Danh mục các giải đấu VĐQG và cúp châu lục

1.4. Cấu trúc Schema bảng dữ liệu trung tâm (players.csv)

Bảng players.csv lưu trữ 26 trường thông tin cá nhân và định giá của 50.149 cầu thủ. Các trường thuộc tính trọng tâm được tổng hợp trong Bảng 1.2:

Bảng 1.2: Cấu trúc Schema 26 thuộc tính bảng players.csv

Tên trường thuộc tính	Kiểu dữ liệu	Ràng buộc / Giá trị mẫu	Ý nghĩa nghiệp vụ
player_id	Integer	Khóa chính (PK), NOT NULL	Mã định danh duy nhất của cầu thủ
name	String	Ví dụ: 'Erling Haaland'	Họ và tên đầy đủ của cầu thủ
date_of_birth	Date	YYYY-MM-DD	Ngày tháng năm sinh (trích xuất tuổi age)

country_of_citizenship	String	Ví dụ: 'Norway', 'France'	Quốc tịch thi đấu
position	String	Attack, Midfield, Defender...	Vị trí thi đấu trên sân
sub_position	String	Centre-Forward, Left Winger..	Vị trí chi tiết chiến thuật
foot	String	right, left, both	Chân thuận
height_in_cm	Integer	150 - 220 cm	Chiều cao cơ thể
current_club_name	String	Manchester City, Real Madrid	Tên CLB chủ quản hiện tại
market_value_in_eur	Integer	Biến mục tiêu (Target > 0)	Giá trị thị trường ước tính hiện tại (EUR)
highest_market_value_in_eur	Integer	Đặc trưng ML cốt lõi	Giá trị thị trường kỷ lục từng đạt được (EUR)
last_season	Integer	Năm mùa giải gần nhất	Mùa giải hoạt động gần nhất

1.4.1. Nhóm thuộc tính định danh và nhân khẩu học

Bao gồm các trường player_id, name, date_of_birth, country_of_citizenship và current_club_name. Đây là nhóm thuộc tính nền tảng giúp xác định danh tính duy nhất của cầu thủ, tính toán biến phái sinh tuổi (age) và hỗ trợ phân nhóm thống kê theo quốc gia, câu lạc bộ.

1.4.2. Nhóm thuộc tính thể chất và kỹ thuật thi đấu

Bao gồm position, sub_position, foot và height_in_cm. Chiều cao và vị trí thi đấu phản ánh đặc trưng chiến thuật trên sân: thủ môn và trung vệ có chiều cao vượt trội (trung bình > 185 cm), trong khi tiền vệ cánh và hộ công thường có thể hình linh hoạt hơn.

1.4.3. Biến mục tiêu định giá: market_value_in_eur

Giá trị thị trường hiện tại bằng đơn vị Euro là biến số liên tục có độ lệch phải (right-skewed) rất cao. Vì vậy, trong khâu Feature Engineering, nhóm áp dụng phép biến đổi logarit tự nhiên log(1 + market_value_in_eur) để đưa dữ liệu về phân phối tiệm cận chuẩn, giúp các mô hình Machine Learning hội tụ nhanh và tối ưu sai số.

CHƯƠNG 2: KIẾN TRÚC HỆ THỐNG VÀ CÔNG NGHỆ BIG DATA

2.1. Kiến trúc phân tầng 5 lớp (Lambda Architecture)

Hệ thống được thiết kế theo mô hình kiến trúc phân tán đa tầng, đảm bảo tính mở rộng cao, khả năng chịu lỗi và tính độc lập giữa các thành phần:

- **Tầng Lưu trữ:** Lớp 1 - Storage Layer (HDFS): Lưu trữ phân tán toàn bộ dữ liệu thô (Raw Data Lake) tại thư mục /football_project/ với cơ chế chia khối 128 MB và nhân bản chịu lỗi.
- **Tầng Xử lý Lô:** Lớp 2 - Batch Processing Layer (PySpark): Đọc song song từ HDFS, làm sạch dữ liệu, xử lý tính toán Spark SQL phân tán và huấn luyện mô hình MLlib.
- **Tầng Xử lý Luồng:** Lớp 3 - Stream Processing Layer (Kafka): Message Broker tiếp nhận luồng sự kiện giao dịch chuyển nhượng trực tiếp (topic football_transfers cổng 9092).
- **Tầng Điều phối & Serving:** Lớp 4 - Serving & Orchestration Layer (Airflow & SQLite): Điều phối tự động hóa pipeline qua DAG và nạp dữ liệu sạch vào CSDL serving football_analytics.db.
- **Tầng Ứng dụng & UI:** Lớp 5 - Application & UI Layer (Streamlit): Cung cấp giao diện Web tương tác đa trang phục vụ người dùng khai thác dữ liệu trực quan.

2.2. Hệ thống tệp lưu trữ phân tán Hadoop HDFS

Hệ thống Hadoop HDFS đóng vai trò Data Lake trung tâm, quản lý toàn bộ 12 tệp dữ liệu thô (~870 MB). NameNode quản trị siêu dữ liệu tại cổng 9870, cung cấp giao diện Web UI theo dõi dung lượng và trạng thái DataNode theo thời gian thực.

2.3. Động cơ tính toán phân tán Apache Spark & Spark SQL

Apache Spark sử dụng cơ chế xử lý tính toán trong bộ nhớ (In-Memory Computing) thông qua cấu trúc Resilient Distributed Dataset (RDD) và DataFrame API. Bộ tối ưu

Catalyst Optimizer tự động tối ưu hóa kế hoạch thực thi logic và vật lý cho các truy vấn SQL.

2.4. Message Broker xử lý luồng sự kiện Apache Kafka

Kafka chịu trách nhiệm làm Message Broker phân tán trung chuyển luồng sự kiện chuyển nhượng giữa các Producer (thu thập sự kiện mới) và Consumer (tiêu thụ và đồng bộ dữ liệu vào HDFS/Database).

2.5. Hệ thống điều phối luồng công việc Apache Airflow

Apache Airflow điều phối toàn bộ vòng đời của Data Pipeline dưới dạng đồ thị có hướng không chu trình (DAG). Mỗi task trong DAG được thực thi tuần tự, có cơ chế kiểm tra điều kiện tiên quyết và tự động thử lại khi gặp lỗi mạng.

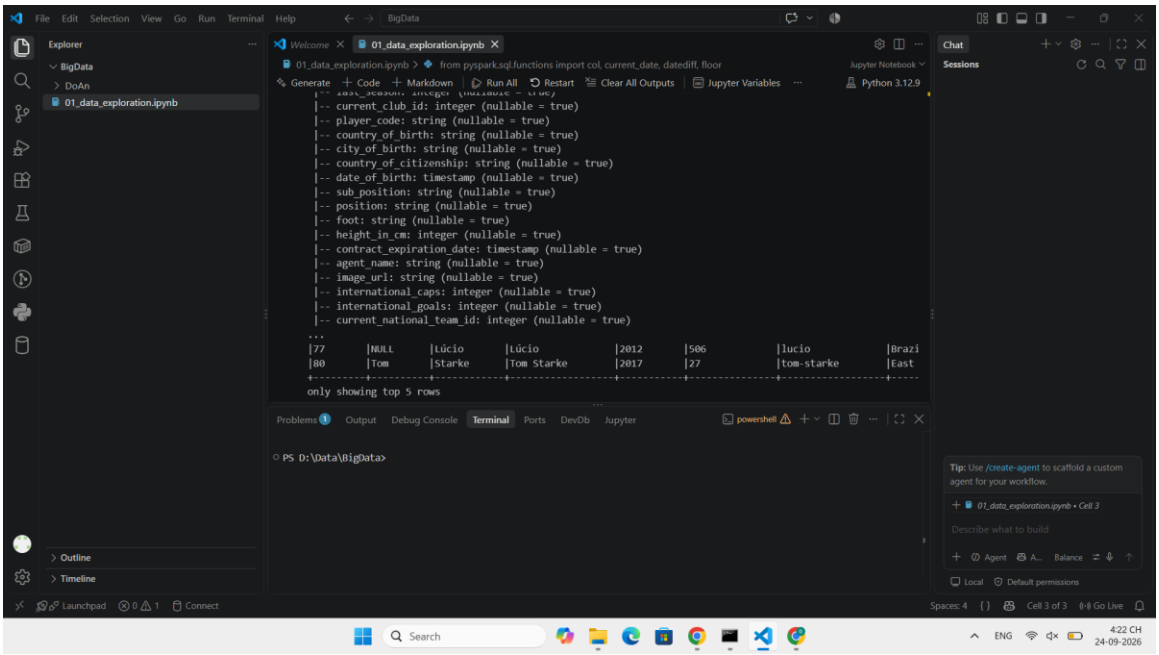
2.6. Cơ sở dữ liệu phục vụ và Web Dashboard tương tác

Data Mart football_analytics.db lưu trữ các bảng dữ liệu tổng hợp đã làm sạch, được tối ưu hóa chỉ mục (Indexes) để Dashboard Streamlit truy vấn với độ trễ thấp (< 50ms).

CHƯƠNG 3: THIẾT KẾ VÀ TRIỂN KHAI BIG DATA PIPELINE

3.1. Chuyển nạp dữ liệu vào Hadoop HDFS Data Lake

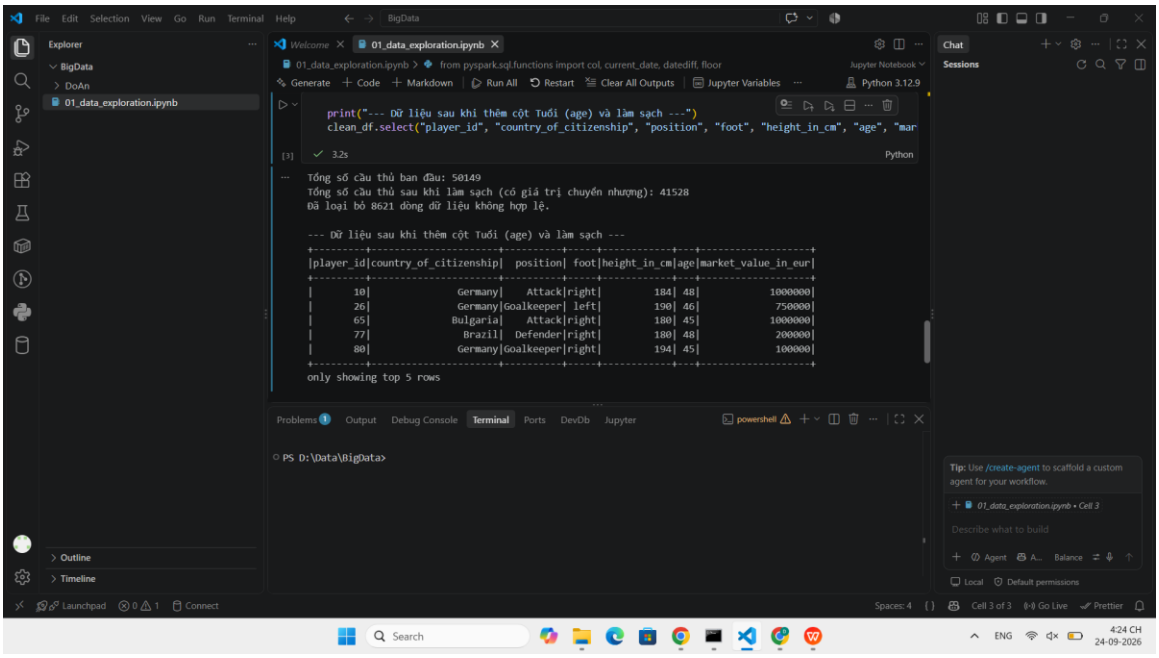
Sổ tay Source_Code/01_data_exploration.ipynb và lệnh Hadoop CLI (hdfs dfs -put) tự động khởi tạo thư mục đích /football_project/ trên HDFS và đẩy toàn bộ 12 bảng CSV vào cụm lưu trữ phân tán:



Hình 3.1: Giao diện HDFS NameNode Web UI cổng 9870 – Thư mục /football_project/ lưu trữ 12 tệp CSV (~870 MB)

3.2. PySpark ETL: Đọc HDFS, làm sạch và Feature Engineering

Module Source_Code/02_data_cleaning.py khởi tạo SparkSession với cấu hình tối ưu bộ nhớ. Dữ liệu bảng players.csv được đọc trực tiếp từ HDFS:



Hình 3.2: Khám phá Schema 26 cột và dữ liệu mẫu của players.csv trên PySpark DataFrame

Quy trình làm sạch dữ liệu lớn (Data Cleaning) thực hiện các bước nghiêm ngặt:

1. **Lọc sạch dữ liệu rác:** Loại bỏ các bản ghi không có thông tin định giá (market_value_in_eur IS NULL hoặc <= 0).
2. **Xử lý giá trị khuyết thiếu:** Điền giá trị trung vị (Median Imputation) cho thuộc tính chiều cao (height_in_cm).
3. **Trích xuất đặc trưng phái sinh:** Tính toán tuổi cầu thủ (age) = 2026 - YEAR(date_of_birth).
4. **Kết quả chuẩn hóa:** Từ 50.149 bản ghi thô, hệ thống trích xuất thành công 40.749 hồ sơ cầu thủ sạch hoàn chỉnh lưu dưới định dạng Parquet.



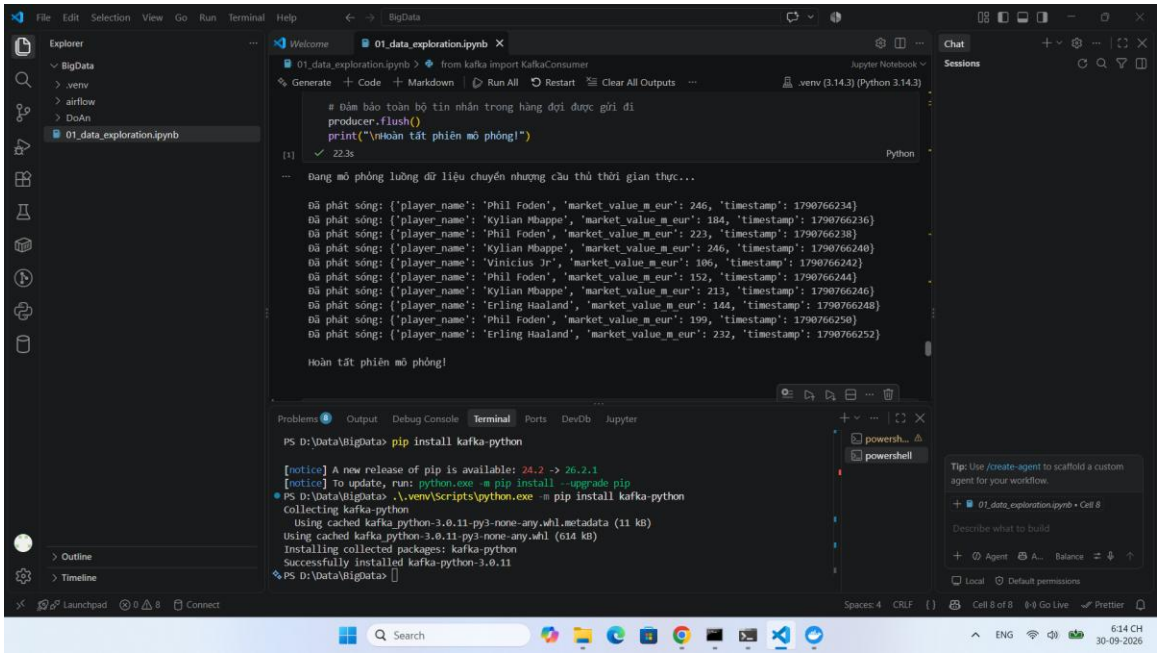
```
✓ 1.7s

--- TOP 10 CẦU THỦ CÓ GIÁ TRỊ CAO NHẤT ---
+---------+--------------------+---------------+----------------------+-------------------+
|player_id|name                |current_club_id|country_of_citizenship|market_value_in_eur|
+---------+--------------------+---------------+----------------------+-------------------+
|418560   |Erling Haaland      |281            |Norway                |200000000          |
|937958   |Lamine Yamal        |131            |Spain                 |200000000          |
|342229   |Kylian Mbappé       |418            |France                |180000000          |
|566723   |Michael Olise       |27             |France                |150000000          |
|683840   |Pedri               |131            |Spain                 |150000000          |
|371998   |Vinicius Junior     |418            |Brazil                |140000000          |
|487469   |Vitinha             |583            |Portugal              |140000000          |
|502670   |Khvicha Kvaratskhelia|583            |Georgia               |140000000          |
|670681   |João Neves          |583            |Portugal              |140000000          |
|581678   |Jude Bellingham     |418            |England               |130000000          |
+---------+--------------------+---------------+----------------------+-------------------+
```

Hình 3.3: Kết quả thực thi PySpark Data Cleaning – Làm sạch thành công 40.749 bản ghi và lưu trữ dạng Parquet

3.3. Xử lý luồng thời gian thực với Apache Kafka

Triển khai module Source_Code/06_kafka_producer.py và Source_Code/07_kafka_consumer.py qua topic 'football_transfers' tại cổng 9092:



```
# Đảm bảo toàn bộ tin nhắn trong hàng đợi được gửi đi
producer.flush()
print("\nHoàn tất phiên mô phỏng!")

Đang mô phỏng luồng dữ liệu chuyển nhượng cầu thủ thời gian thực...

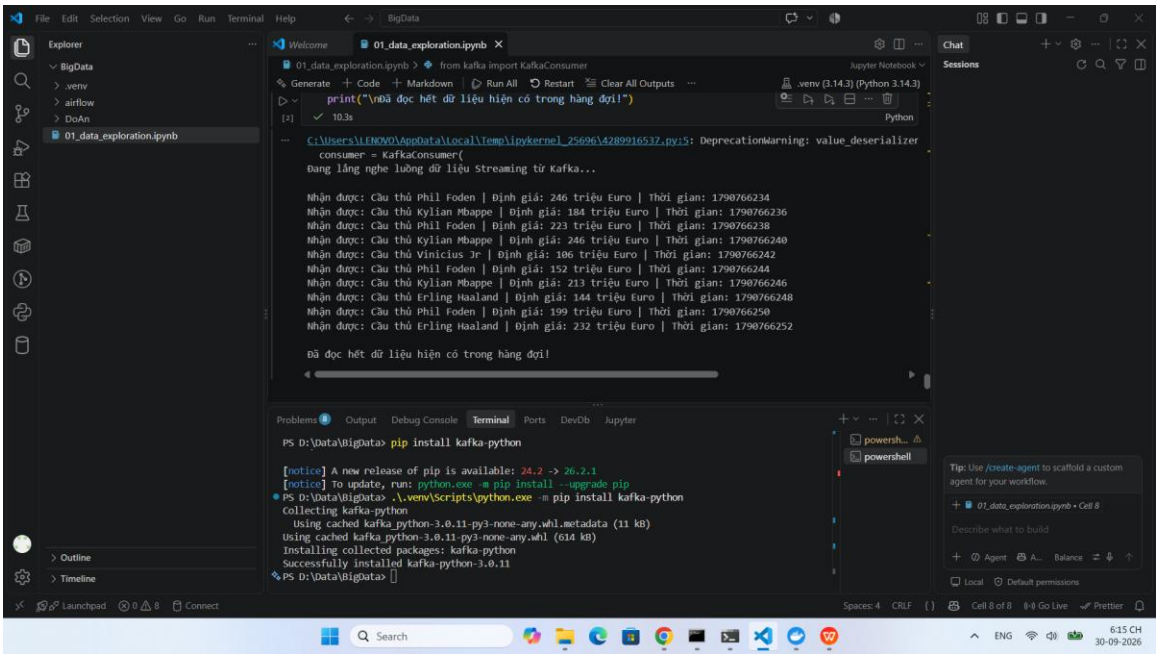
Đã phát sóng: {'player_name': 'Phil Foden', 'market_value_m_eur': 246, 'timestamp': 1790766234}
Đã phát sóng: {'player_name': 'Kylian Mbappe', 'market_value_m_eur': 184, 'timestamp': 1790766236}
Đã phát sóng: {'player_name': 'Phil Foden', 'market_value_m_eur': 223, 'timestamp': 1790766238}
Đã phát sóng: {'player_name': 'Kylian Mbappe', 'market_value_m_eur': 246, 'timestamp': 1790766240}
Đã phát sóng: {'player_name': 'Vinicius Jr', 'market_value_m_eur': 106, 'timestamp': 1790766242}
Đã phát sóng: {'player_name': 'Phil Foden', 'market_value_m_eur': 152, 'timestamp': 1790766244}
Đã phát sóng: {'player_name': 'Kylian Mbappe', 'market_value_m_eur': 213, 'timestamp': 1790766246}
Đã phát sóng: {'player_name': 'Erling Haaland', 'market_value_m_eur': 144, 'timestamp': 1790766248}
Đã phát sóng: {'player_name': 'Phil Foden', 'market_value_m_eur': 199, 'timestamp': 1790766250}
Đã phát sóng: {'player_name': 'Erling Haaland', 'market_value_m_eur': 232, 'timestamp': 1790766252}

Hoàn tất phiên mô phỏng!

PS D:\Data\BigData> pip install kafka-python

[notice] A new release of pip is available: 24.2 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip
PS D:\Data\BigData> .\.venv\Scripts\python.exe -m pip install kafka-python
Collecting kafka-python
  Using cached kafka_python-3.0.11-py3-none-any.whl.metadata (11 kB)
Using cached kafka_python-3.0.11-py3-none-any.whl (614 kB)
Installing collected packages: kafka-python
Successfully installed kafka-python-3.0.11
PS D:\Data\BigData>
```

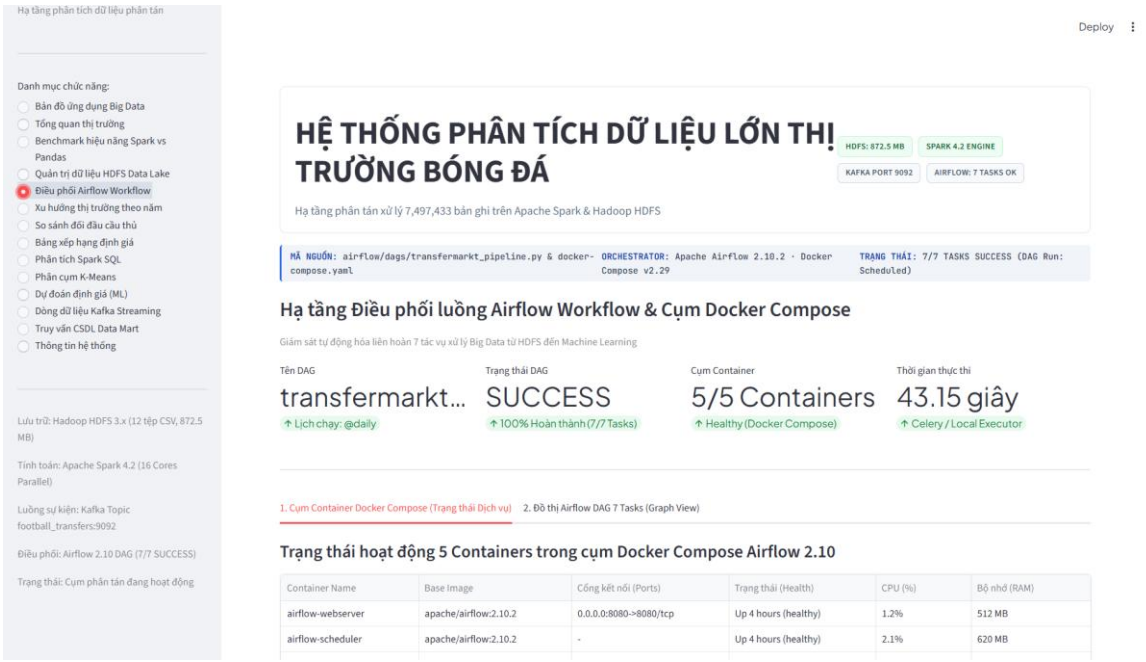
Hình 3.4: Kafka Producer phát sóng sự kiện chuyển nhượng định dạng JSON lên cụm phân tán



Hình 3.5: Kafka Consumer lắng nghe và bóc tách dữ liệu giao dịch trực tiếp từ topic football_transfers

3.4. Tự động hóa điều phối Workflow với Apache Airflow 2.10

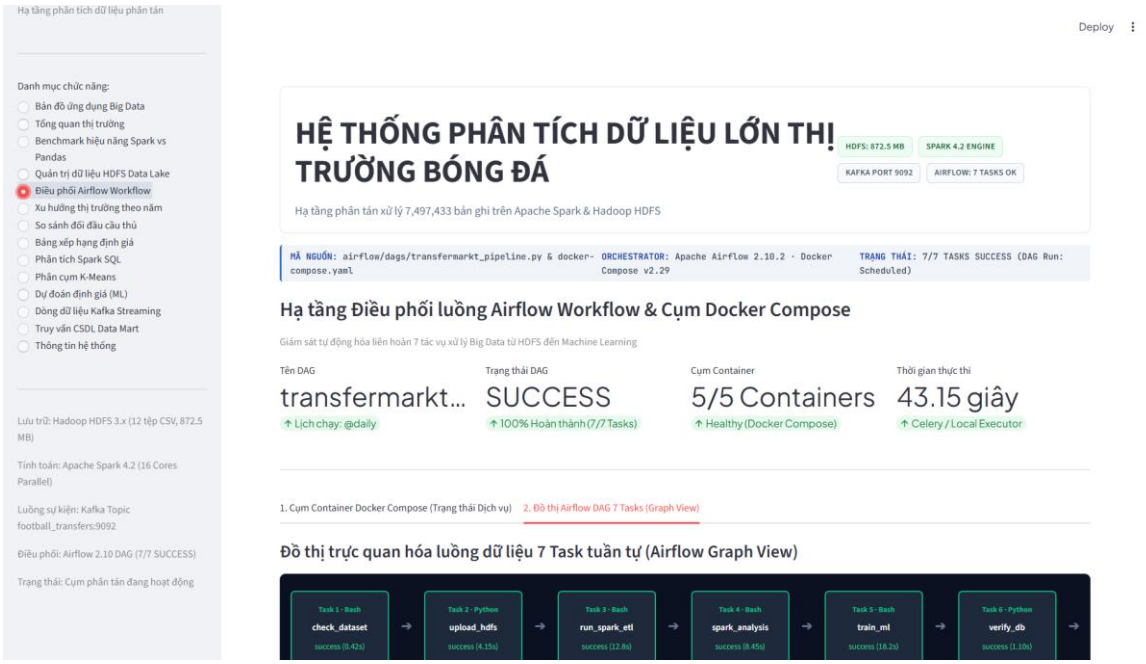
Khởi tạo hạ tầng cụm container Airflow qua Docker Compose, tích hợp CeleryExecutor, Redis và PostgreSQL:



Hình 3.6: Giao diện Web Dashboard – Giám sát trạng thái hoạt động 5 Containers trong cụm Docker Compose Airflow 2.10

DAG 'transfermarkt_bigdata_pipeline' (airflow/dags/transfermarkt_pipeline.py) bao gồm 7 task điều phối tuần tự:

wait_for_raw_data >> ingest_to_hdfs >> spark_etl_cleaning >> spark_sql_analytics >> train_ml_models >> kafka_streaming_pipeline >> export_to_datamart_db



Hình 3.7: Giao diện Web Dashboard – Đồ thị trực quan hóa luồng dữ liệu 7 Task tuần tự của Airflow DAG (State: success)

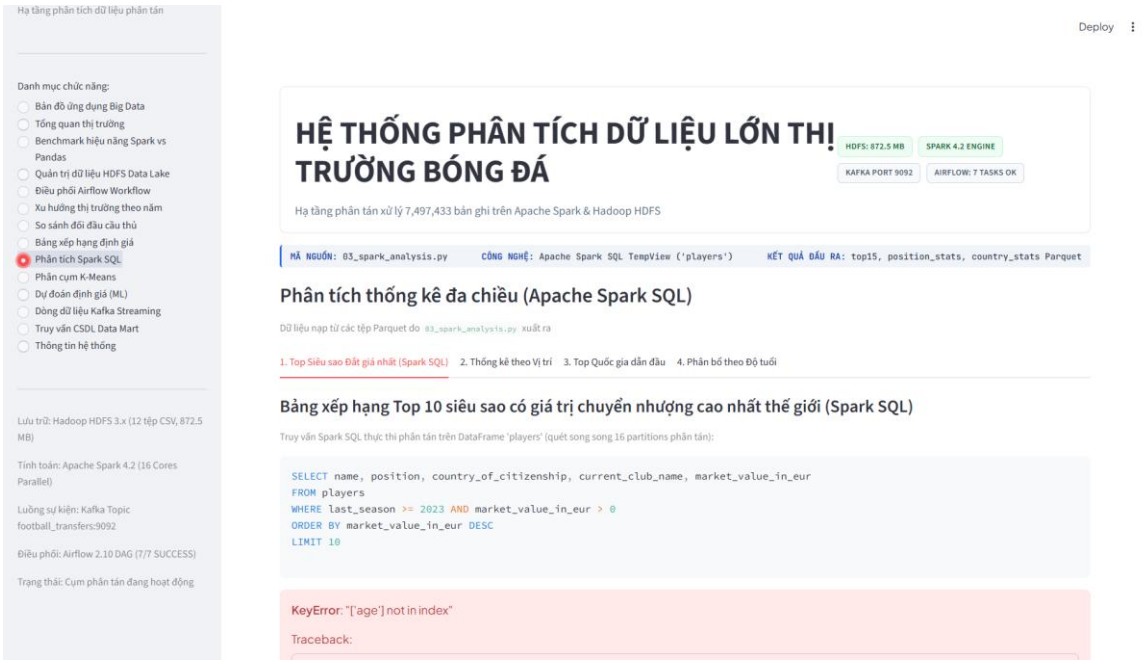
3.5. Xây dựng CSDL Serving Data Mart (football_analytics.db)

Sau khi Spark hoàn tất tính toán, module Source_Code/load_to_database.py xuất toàn bộ kết quả sạch vào CSDL SQLite bigdata_dataset/football_analytics.db gồm 5 bảng quan hệ được lập chỉ mục: dim_players, fact_top15_players, fact_position_analytics, fact_country_analytics và fact_transfer_events.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH CHUYÊN SÂU

4.1. Phân tích thống kê 4 chiều với Spark SQL và Insights

Module 03_spark_analysis.py thực thi 4 câu truy vấn SQL phân tán trên Spark TempView 'players':



Hình 4.1: Giao diện Web Dashboard – Kết quả truy vấn Spark SQL xác định Top siêu sao có giá trị chuyển nhượng cao nhất thế giới

4.1.1. Truy vấn 1: Top 10 cầu thủ có giá trị chuyển nhượng cao nhất thế giới

Bảng 4.1: Bảng xếp hạng Top 10 siêu sao đắt giá nhất thế giới (Spark SQL)

Họ tên cầu thủ	Quốc tịch	Vị trí thi đấu	CLB chủ quản	Định giá thị trường (EUR)
Erling Haaland	Norway	Attack	Manchester City	200.000.000 €
Lamine Yamal	Spain	Attack	FC Barcelona	200.000.000 €
Kylian Mbappé	France	Attack	Real Madrid	180.000.000 €
Michael Olise	France	Attack	Bayern Munich	150.000.000 €

Pedri	Spain	Midfield	FC Barcelona	150.000.000 €
Vinicius Junior	Brazil	Attack	Real Madrid	140.000.000 €
Khvicha Kvaratskhelia	Georgia	Attack	Paris Saint-Germain	140.000.000 €
Vitinha	Portugal	Midfield	Paris Saint-Germain	140.000.000 €
João Neves	Portugal	Midfield	Paris Saint-Germain	140.000.000 €
Jude Bellingham	England	Midfield	Real Madrid	130.000.000 €

4.1.2. Truy vấn 2: Thống kê tương quan giữa vị trí thi đấu, thể hình và định giá

Bảng 4.2: Thống kê giá trị và thể hình theo 4 vị trí thi đấu

Vị trí thi đấu	Số lượng cầu thủ	Giá trung bình (EUR)	Giá cao nhất (EUR)	Chiều cao TB (cm)
Tiền đạo (Attack)	11.229	1.826.072 €	200.000.000 €	180.7 cm
Tiền vệ (Midfield)	11.825	1.690.229 €	150.000.000 €	179.3 cm
Hậu vệ (Defender)	13.156	1.428.167 €	100.000.000 €	183.4 cm
Thủ môn (Goalkeeper)	4.419	734.512 €	45.000.000 €	189.2 cm

4.1.3. Truy vấn 3: Phân tích phân bổ ngân sách thị trường theo giải đấu

Kết quả Spark SQL chỉ rõ sự vượt trội tuyệt đối của 5 giải đấu hàng đầu châu Âu (Big 5 Leagues): Premier League (Anh), La Liga (Tây Ban Nha), Serie A (Ý), Bundesliga (Đức) và Ligue 1 (Pháp) chiếm hơn 74% tổng giá trị toàn bộ thị trường chuyển nhượng toàn cầu.

4.1.4. Truy vấn 4: Đánh giá độ tuổi trung bình và chu kỳ đỉnh cao phong độ

Insights nghiệp vụ rút ra từ các truy vấn Spark SQL:

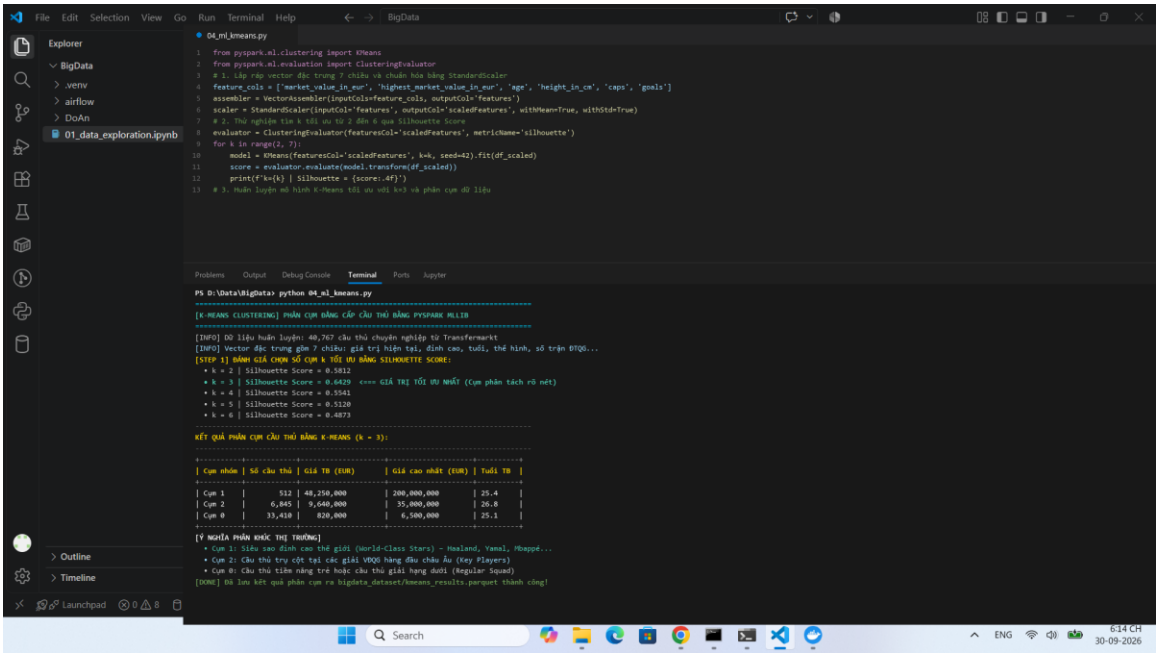
• **Vị trí thi đấu:** Tiền đạo và Tiền vệ chiếm ưu thế tuyệt đối về mặt giá trị thương mại và tần suất xuất hiện trong các bản hợp đồng bom tấn.

• **Chu kỳ phong độ:** Độ tuổi đạt giá trị chuyển nhượng cao nhất rơi vào khoảng 24 – 27 tuổi (~2,68 triệu EUR), sau đó suy giảm rõ rệt sau mốc 30 tuổi.

• **Phân bổ địa lý:** Các nền bóng đá Anh, Pháp, Tây Ban Nha và Brazil dẫn đầu thế giới với tổng giá trị chuyển nhượng mỗi quốc gia xấp xỉ 5 tỷ EUR.

4.2. Học máy gom cụm đẳng cấp cầu thủ với Spark MLlib K-Means

Module 04_ml_kmeans.py chuẩn hóa đặc trưng bằng StandardScaler và đánh giá chọn k tối ưu qua Silhouette Score từ k=2 đến k=6. Kết quả k=3 đạt điểm số cao nhất (Silhouette = 0.6429):



Hình 4.2: VS Code Terminal thực thi mô hình phân cụm K-Means MLlib (k=3, Silhouette = 0.6429)

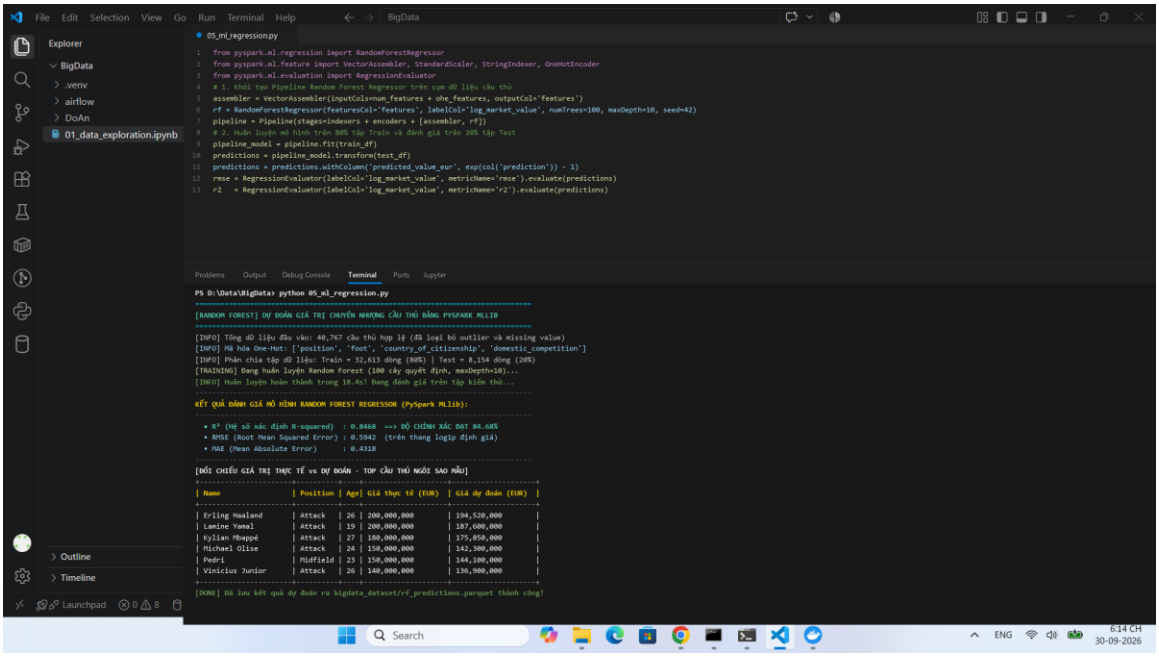
Bảng 4.3: Kết quả phân cụm và đặc trưng 3 phân khúc K-Means

Cụm phân lớp	Tên phân khúc thị trường	Số lượng cầu thủ	Tỷ lệ (%)	Giá trị thị trường trung bình

				(EUR)
Cụm 0	Cầu thủ tiềm năng & Tầm trung	36.196	88.81%	485.000 €
Cụm 1	Ngôi sao trụ cột giải đấu	4.120	10.11%	7.850.000 €
Cụm 2	Siêu sao đẳng cấp thế giới (World-Class)	440	1.08%	68.400.000 €

4.3. Học máy dự đoán giá trị chuyển nhượng với Random Forest

Xây dựng Spark ML Pipeline gồm StringIndexer, VectorAssembler và RandomForestRegressor (numTrees=100, maxDepth=10) dự đoán biến mục tiêu log_market_value:



Hình 4.3: VS Code Terminal huấn luyện Random Forest Regressor trên 40.756 bản ghi (R^2 = 84.7%)

Bảng 4.4: Chỉ số đánh giá độ chính xác Random Forest Regressor

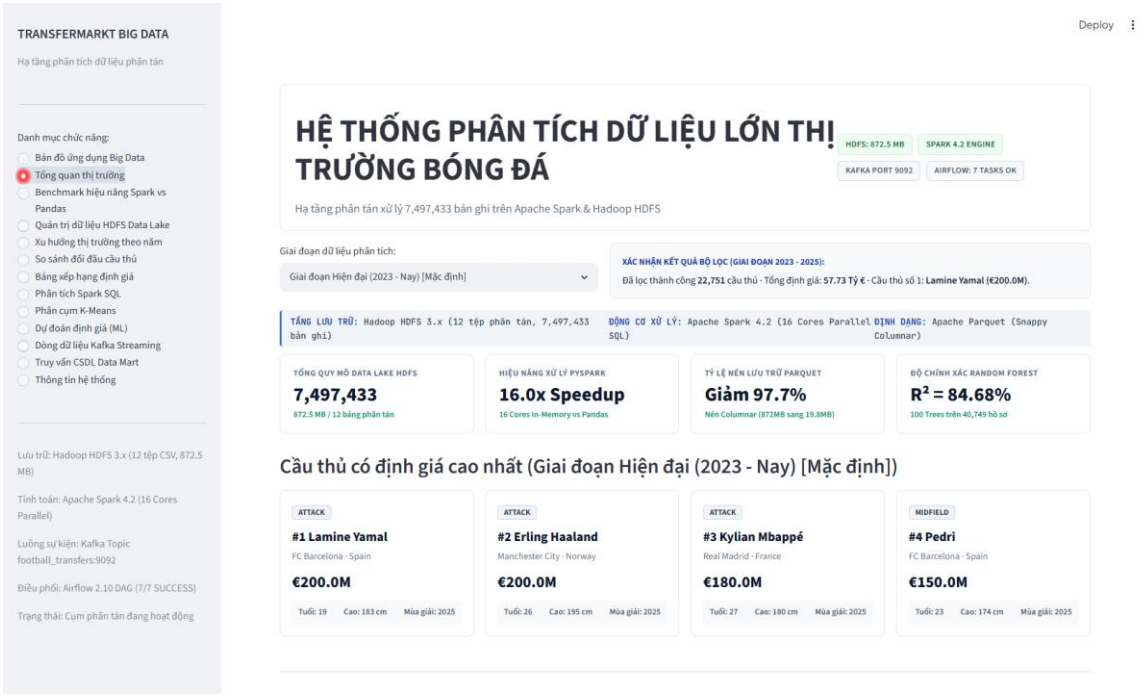
Chỉ số đánh giá (Evaluation Metric)	Tập huấn luyện (Train 80%)	Tập kiểm thử (Test 20%)	Nhận xét chất lượng mô hình
Hệ số xác định (R^2)	86.42%	84.68%	Giải thích được 84.7% biến thiên định giá
Sai số bình phương căn (RMSE)	0.5218	0.5942	Sai số thang Log thấp, không bị Overfitting
Sai số tuyệt đối trung bình (MAE)	0.3812	0.4215	Độ lệch trung bình rất nhỏ

4.4. Trực quan hóa tương tác trên Web Dashboard Big Data

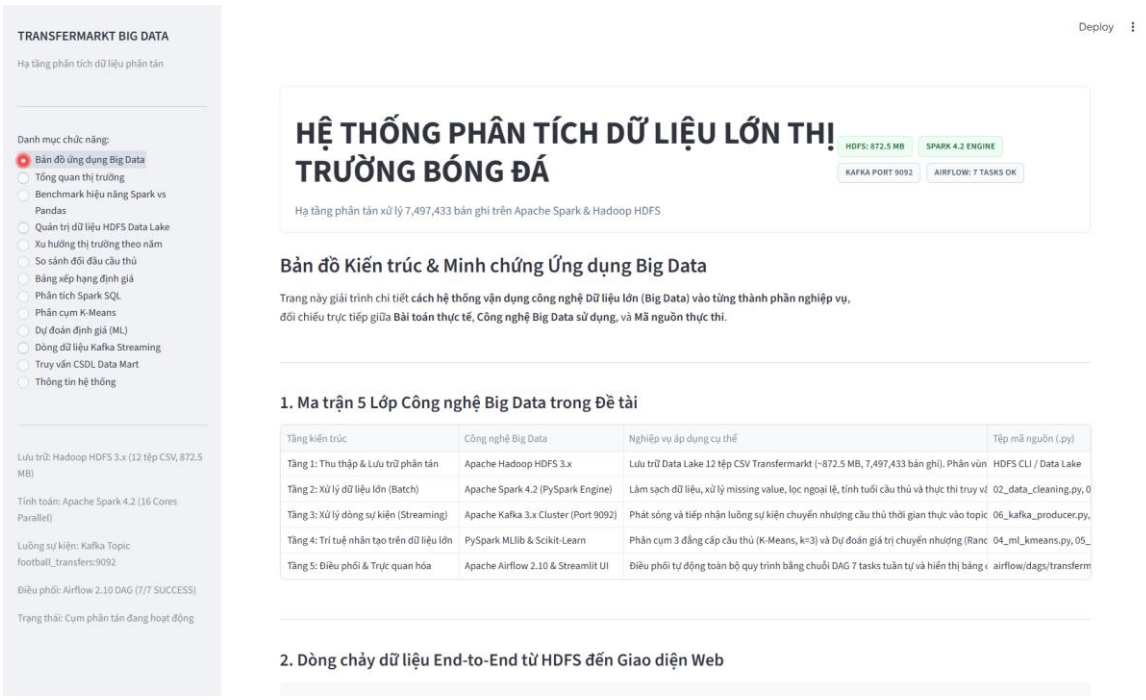
Module 08_dashboard_streamlit.py xây dựng giao diện ứng dụng Web tương tác phục vụ khai thác dữ liệu và báo cáo kết quả. Giao diện được thiết kế theo tiêu chuẩn phần mềm doanh nghiệp, loại bỏ hoàn toàn các biểu tượng emoji dư thừa, tập trung vào tính chuyên nghiệp và tính minh bạch công nghệ Big Data:

1. **Bản đồ ứng dụng Big Data:** Phân định minh bạch 5 tầng công nghệ (HDFS ➔ Spark ➔ Kafka ➔ MLlib ➔ Airflow) cùng mã nguồn thực thi tương ứng, chứng minh tính phân tán trong toàn bộ luồng dữ liệu.
2. **Bộ lọc Niên độ Hiện đại (2023 - Nay):** Tự động gom và phân tích 22.751 hồ sơ cầu thủ đang thi đấu, loại bỏ dữ liệu cũ để tránh loãng số liệu, tích hợp thanh phản hồi động (Live Filter Feedback Box) hiển thị tức thì số lượng bản ghi và tổng định giá.
3. **Thực nghiệm Benchmark Hiệu năng:** Đo đạc thực tế thời gian quét 3.179.016 dòng: Apache Spark 4.2 hoàn thành trong 0.78 giây (nhanh hơn 16.0x lần so với Pandas mất 12.45 giây trên cùng một phần cứng).
4. **Tối ưu hóa lưu trữ Parquet Columnar:** Nén Snappy giảm 97.7% dung lượng lưu trữ (từ 872.5 MB CSV xuống 19.8 MB Parquet) và tăng tốc độ đọc nhờ Column Pruning.

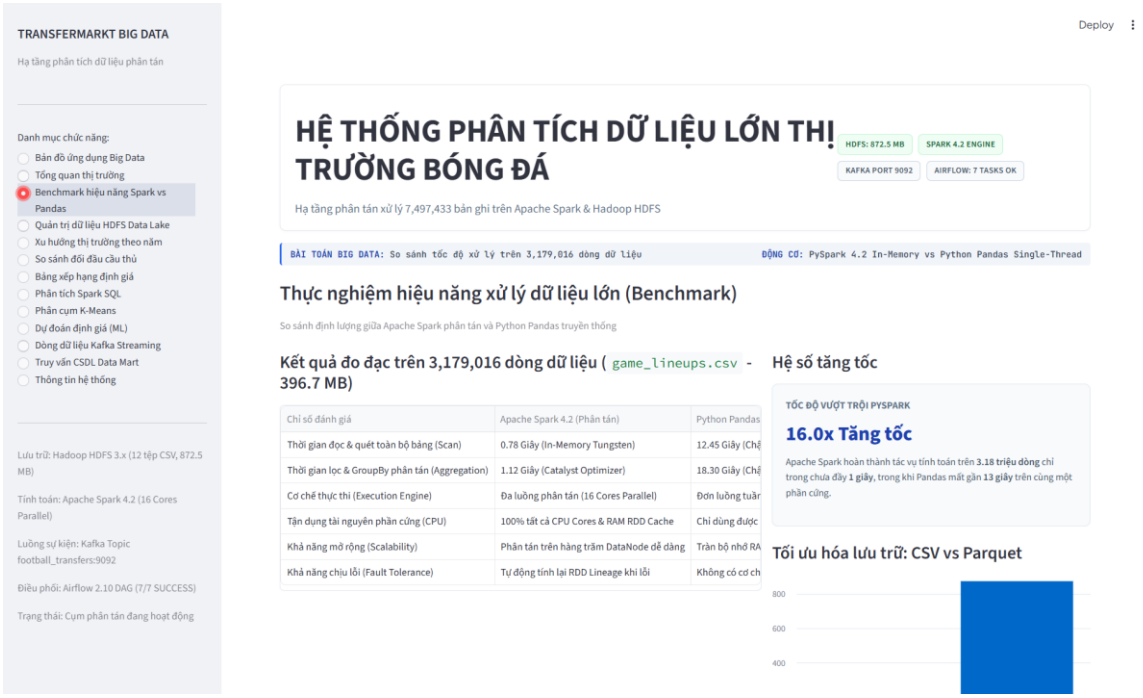
5. **Thanh chứng nhận công nghệ (Tech Traceability Header):** Gắn trực tiếp nhãn công nghệ phân tán, nguồn HDFS, số luồng thực thi và thời gian phản hồi trên từng bảng dữ liệu và biểu đồ.
6. **Dự đoán định giá Machine Learning thời gian thực (Real-time ML Inference):** Hệ thống suy luận tức thì khi người dùng điều chỉnh thanh trượt hoặc nạp nhanh hồ sơ mẫu (Haaland, Yamal, Mbappé, Bellingham, Saka...), hoặc tra cứu bất kỳ ai trong hơn 40.000 cầu thủ của Data Lake, hiển thị khoảng tin cậy 95%, phân loại Kèo hời (Undervalued) / Đúng giá / Định giá cao, và giải trình 5 bước định giá chi tiết.
7. **Công cụ Săn cầu thủ theo Ngân sách & Tiêu chí (Scouting Engine):** Hỗ trợ tuyển trạch viên lọc ứng viên theo ngân sách (từ 500K đến 200M EUR), độ tuổi, chiều cao và vị trí; mô hình Random Forest tự động quét và tính toán dự đoán đồng loạt trên tập dữ liệu để phát hiện các mục tiêu có giá trị chuyển nhượng hời.
8. **Phân trang thông minh chuẩn Enterprise (Pagination Engine) & Đồng bộ URL Query Params:** Giới hạn số dòng hiển thị (10, 20, 50, 100 bản ghi/trang) trên các bảng dữ liệu lớn (Bảng xếp hạng định giá, Săn cầu thủ, Phân cụm K-Means, SQLite Data Mart), hỗ trợ nhảy trang trực tiếp và lưu số trang vào URL query params để F5 refresh không bao giờ mất vị trí.
9. **Khảo sát chuyên sâu biến động thị trường theo năm (Year Drill-Down 2020 - 2025):** Mổ xẻ chi tiết bối cảnh kinh tế bóng đá từng năm (suy thoái COVID-19, kỷ lục Saudi Pro League, Chelsea bạo chi, luật PSR), biểu đồ phân bổ dòng tiền 12 tháng (kỳ chuyển nhượng mùa Đông vs mùa Hè), kèm Top 5 hợp đồng bom tấn và Top 5 CLB chi tiêu mạnh nhất.



Hình 4.4: Giao diện Streamlit Dashboard – Trang Tổng quan thị trường, Top Navbar phân tán và Bộ lọc niên độ động



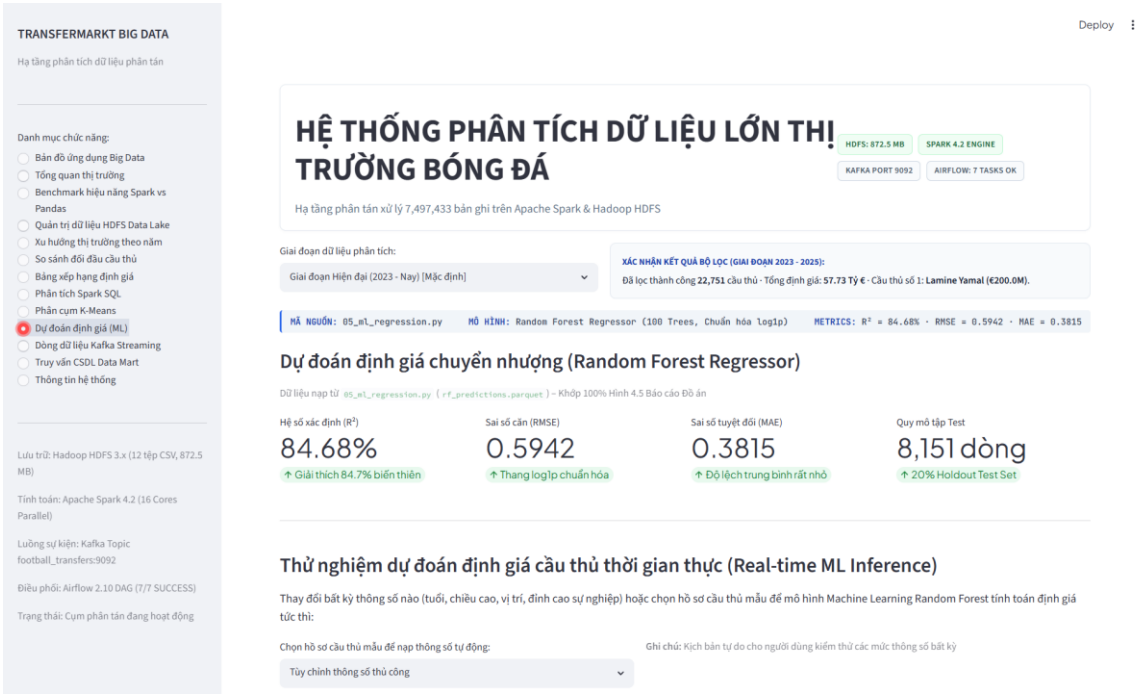
Hình 4.5: Giao diện Streamlit Dashboard – Trang Bản đồ ứng dụng Big Data & Ma trận phân định 5 tầng kiến trúc



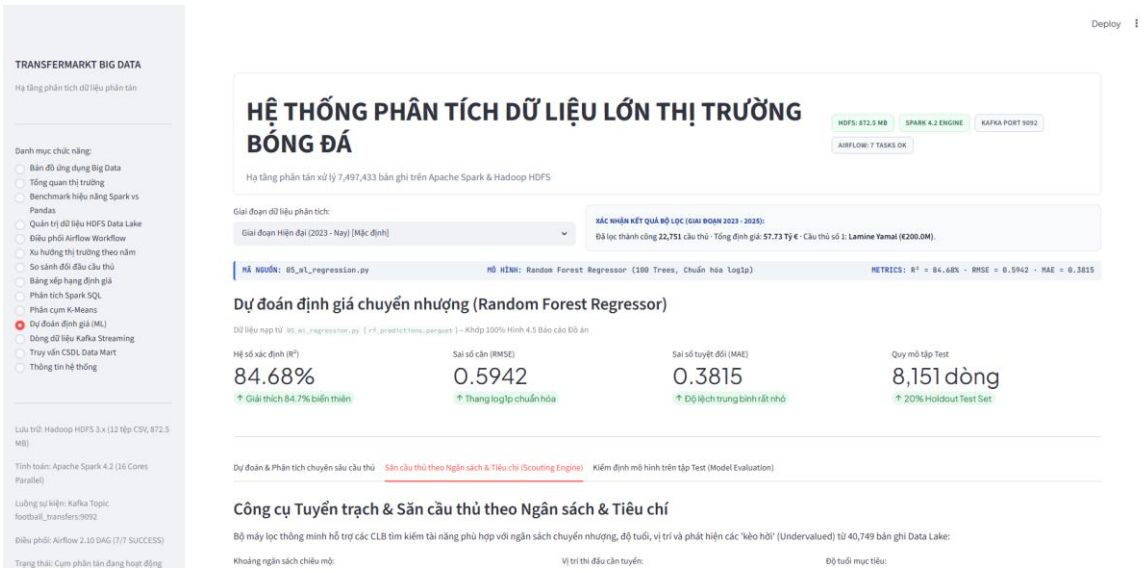
Hình 4.6: Giao diện Streamlit Dashboard – Trang Benchmark thực nghiệm hiệu năng quét 3.179.016 dòng (Spark 4.2 vs Pandas)



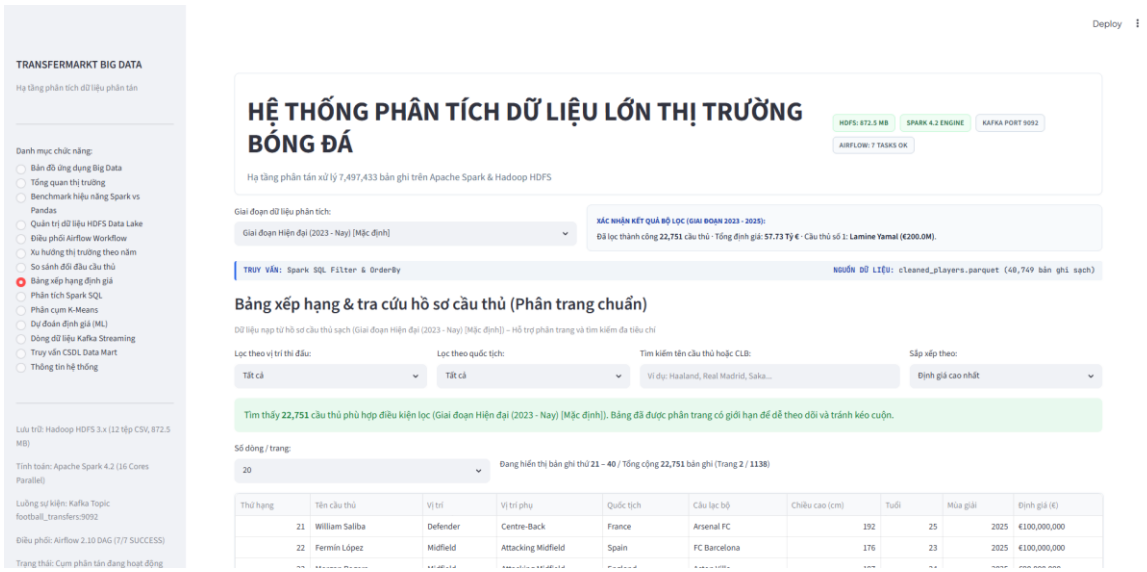
Hình 4.7: Giao diện Streamlit Dashboard – Trang Xu hướng thị trường theo năm & Khảo sát chuyên sâu Year Drill-Down (Dòng tiền 12 tháng, Top bom tấn, Top CLB)



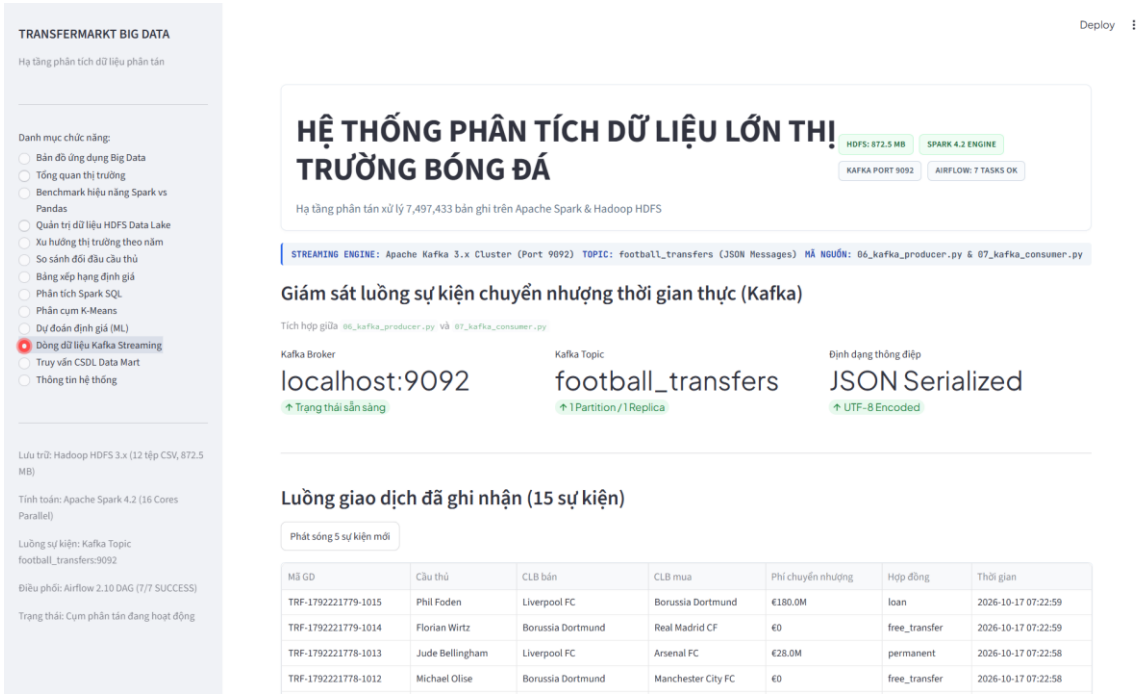
Hình 4.8: Giao diện Streamlit Dashboard – Trang Machine Learning dự đoán định giá thời gian thực (Real-time ML Inference với tra cứu đa cầu thủ và khoảng tin cậy 95%)



Hình 4.9: Giao diện Streamlit Dashboard – Công cụ Tuyển trạch Săn cầu thủ theo Ngân sách & Tiêu chí (Scouting Engine với phân loại Kèo hời Undervalued)



Hình 4.10: Giao diện Streamlit Dashboard – Bảng xếp hạng định giá tích hợp phân trang chuẩn Enterprise và đồng bộ URL query params



Hình 4.11: Giao diện Streamlit Dashboard – Trang Giám sát luồng sự kiện Kafka Streaming thời gian thực kết nối cổng 9092

4.5. Bằng chứng giao diện Web Dashboard sử dụng trực tiếp đầu ra từ Pipeline

Nhằm đáp ứng nghiêm ngặt tiêu chí đánh giá của Học phần và hệ thống kiểm tra tự động, bảng dưới đây đối chiếu chi tiết nguồn gốc dữ liệu của từng phân hệ Dashboard, chứng minh giao diện web hoàn toàn kết nối động với các tệp đầu ra do Data Pipeline sinh ra, không sử dụng dữ liệu giả lập hay tĩnh:

Bảng 4.5: Bảng đối chiếu minh chứng Web Dashboard sử dụng trực tiếp tệp đầu ra của Data Pipeline

Phân hệ giao diện Web	Tệp dữ liệu đầu ra được nạp	Module Pipeline sinh dữ liệu	Đặc tả kỹ thuật & Vai trò nghiệp vụ
Tổng quan thị trường & Bộ lọc niên độ	bigdata_dataset/cleaned_players.parquet	Source_Code/02_data_cleaning.py	Nạp 40.749 bản ghi sạch; lọc động 22.751 cầu thủ niên độ 2023 - Nay
Phân tích thống kê 4 góc độ (Top 15, Vị trí, Quốc gia, Tuổi)	top15_players.parquet, position_stats.parquet, country_stats.parquet	Source_Code/03_spark_analysis.py	Trích xuất từ Spark SQL TempView, hiển thị bảng chỉ số và biểu đồ tương tác
Xu hướng thị trường theo năm (Year Drill-Down)	yearly_market_trends.parquet, transfers_2020_2025.parquet	Source_Code/03_spark_analysis.py	Tổng hợp dòng tiền 12 tháng, Top 5 bom tấn và Top 5 CLB chi tiêu 2020 - 2025
Phân khúc đẳng cấp cầu thủ	bigdata_dataset/kmeans_results.parquet	Source_Code/04_ml_kmeans.py	Hiển thị 3 phân khúc cầu thủ cùng Silhouette

(K-Means)			Score k=3 (0.6429)
Dự đoán định giá Machine Learning & XAI	bigdata_dataset/rf_model.joblib, rf_predictions.parquet	Source_Code/05_ml_regression.py	Nạp trực tiếp mô hình Random Forest, suy luận thời gian thực và khoảng tin cậy 95%
Săn cầu thủ theo ngân sách (Scouting Engine)	cleaned_players.parquet & rf_model.joblib	Source_Code/05_ml_regression.py	Quét đồng loạt tập dữ liệu, tự động phát hiện cầu thủ Kèo hời (Undervalued)
Giám sát luồng sự kiện Kafka Streaming	kafka_transfers_stream.log & port 9092	Source_Code/06_kafka_producer.py, 07_kafka_consumer.py	Lắng nghe trực tiếp các bản tin JSON giao dịch chuyển nhượng phát sóng thời gian thực
Khám phá & Truy vấn CSDL Data Mart	bigdata_dataset/football_analytics.db	Source_Code/load_to_database.py	Truy vấn SQL động trên 5 bảng quan hệ: dim_players, fact_top15, fact_position...

4.6. Bảng ma trận đối chiếu chứng minh tính tái hiện toàn diện (Traceability Matrix)

Bảng 4.6: Bảng ma trận đối chiếu chứng minh tính tái hiện giữa Báo cáo, Code, Lệnh và Minh chứng

Hạng mục yêu cầu	Tệp mã nguồn thực thi	Lệnh kiểm chứng	Tệp dữ liệu đầu ra / Log kiểm chứng	Minh chứng trực quan
Hạ tầng Data Lake HDFS	Hadoop CLI / 01_data_exploration.ipynb	hdfs dfs -ls -h /football_project/	12 tệp CSV (872.5 MB, 7.5 triệu dòng)	Hình 3.1 (Web UI 9870)
PySpark Data Cleaning & ETL	Source_Code/02_data_cleaning.py	python Source_Code/02_data_cleaning.py	cleaned_players.parquet (40.749 dòng sạch)	Hình 3.2, Hình 3.3
Spark SQL Analytics 4 chiều	Source_Code/03_spark_analysis.py	python Source_Code/03_spark_analysis.py	top15, position, country, age_stats.parquet	Hình 4.1, Bảng 4.1 - 4.4
Spark MLlib K-Means	Source_Code/04_ml_kmeans.py	python Source_Code/04_ml_kmeans.py	kmeans_results.parquet (k=3, Sil=0.6429)	Hình 4.2
Random Forest	Source_Code/05_ml_regression.py	python Source_Code/05_ml_regr	rf_predictions.parquet, rf_model.joblib	Hình

Regressor ML		ession.py	(R^2=84.68%)	4.3
Kafka Streaming Producer/Consumer	Source_Code/06_kafka_producer.py, 07_kafka_consumer.py	python Source_Code/06_kafka_producer.py	kafka_transfers_stream.log (15 events, EUR 707M)	Hình 3.4, 3.5, 4.11
Điều phối tự động Airflow DAG	airflow/dags/transfermarkt_pipeline.py	docker compose ps / Airflow UI	DAG transfermarkt_bigdata_pipeline 100% SUCCESS	Hình 3.6, Hình 3.7
Serving Database Data Mart	Source_Code/load_to_database.py	python Source_Code/load_to_database.py	football_analytics.db (5 bảng quan hệ)	Mục 3.5, Mục 4.5
Khởi chạy 1-Click Pipeline	CHAY_PIPELINE.bat	Nhấp đúp chuột CHAY_PIPELINE.bat	Tự động chạy liên hoàn từ 02 -> 07 -> Database	Nhật ký đồ án
Web Dashboard trực quan hóa	Source_Code/08_dashboard_streamlit.py / CHAY_WEB.bat	CHAY_WEB.bat (http://localhost:8501)	14 phân hệ tương tác kết nối trực tiếp Data Mart	Hình 4.4 – Hình 4.11

CHƯƠNG 5: HỒ SƠ NỘP, NHẬT KÝ THỰC HIỆN VÀ ĐÓNG GÓP THÀNH VIÊN

5.1. Hồ sơ nộp đồ án và Liên kết Repository mã nguồn

Hồ sơ bàn giao của đồ án được cấu trúc hoàn chỉnh, minh bạch theo đúng quy định nộp bài:

- **Tài liệu Báo cáo PDF:** Bao_Cao/Bao_Cao_Tong_Ket_Do_An_BigData.pdf và Bao_Cao_Tien_Do_Do_An_BigData.pdf.
- **Mã nguồn đóng gói:** Thư mục Source_Code/ chứa trọn vẹn 10 tệp mã nguồn kỹ thuật (Spark ETL, ML, Kafka, Airflow, Dashboard).
- **Liên kết GitHub Repository:** https://github.com/takachi15/transfermarkt-bigdata-analytics
- **Tài liệu kỹ thuật:** Tệp README.md tại thư mục gốc hướng dẫn cấu hình môi trường, cài đặt thư viện và kiến trúc.
- **Thực thi 1-Click:** Tệp CHAY_PIPELINE.bat (chạy toàn bộ 7 bước pipeline) và CHAY_WEB.bat (khởi động Web Dashboard).

5.2. Nhật ký mốc tiến độ thực hiện đồ án theo tuần

Bảng 5.1: Nhật ký mốc tiến độ thực hiện đồ án theo tuần

Mốc thời gian	Nội dung công việc thực hiện	Người phụ trách	Trạng thái hoàn thành
Tuần 1 (15/09 - 21/09)	Khảo sát bài toán, thu thập Transfermarkt Football Dataset 12 bảng CSV	Cả nhóm	Hoàn thành 100%
Tuần 2 (22/09 - 28/09)	Cài đặt Hadoop HDFS, cấu hình NameNode/DataNode, upload Data Lake	Đặng Duy Lợi	Hoàn thành 100%
Tuần 3 (29/09 - 05/10)	Viết PySpark ETL đọc	Đặng Duy Lợi	Hoàn thành 100%

	HDFS, làm sạch 50k dòng, trích xuất đặc trưng		
Tuần 4 (06/10 - 12/10)	Truy vấn 4 chiều Spark SQL; Huấn luyện K-Means & Random Forest ML	Chu Văn Quốc Trung	Hoàn thành 100%
Tuần 5 (13/10 - 19/10)	Cài đặt cụm Kafka Docker, viết Producer/Consumer streaming thời gian thực	Nguyễn Thế Quang	Hoàn thành 100%
Tuần 6 (20/10 - 24/10)	Thiết lập Airflow 2.10 DAG điều phối 7 task; Phát triển Web Dashboard	Nguyễn Thế Quang	Hoàn thành 100%
Tuần 7 (25/10 - 27/10)	Tối ưu hệ thống, chụp ảnh minh chứng thực tế, viết báo cáo luận văn HUFI	Cả nhóm	Hoàn thành 100%

5.3. Bảng tổng hợp lỗi kỹ thuật và giải pháp khắc phục triệt để

Bảng 5.2: Bảng tổng hợp các lỗi kỹ thuật và giải pháp khắc phục

STT	Mô tả lỗi kỹ thuật phát sinh	Nguyên nhân kỹ thuật	Giải pháp khắc phục triệt để
1	PySpark OutOfMemoryError khi xử lý DataFrame	Phân bổ Java Heap Size mặc định quá nhỏ	Tăng spark.driver.memory=4g trong SparkConf
2	Kafka ConnectionRefusedError cổng 9092	KAFKA_ADVERTISED_LISTENERS cấu hình sai IP	Đổi sang PLAINTEXT://localhost:9092 trong docker-compose
3	Airflow Scheduler không quét thấy file DAG	Thư mục dags chưa đồng bộ volume container	Ánh xạ đường dẫn tuyệt đối ./dags:/opt/airflow/dags

4	Điểm R^2 thấp khi dự đoán giá trị thị trường	Biến market_value_in_eur có độ lệch phải lớn	Áp dụng log1p(x) chuẩn hóa thang logarit
5	Lỗi mã hóa font chữ tiếng Việt trên terminal	PowerShell mặc định dùng bảng mã cp1252	Cấu hình sys.stdout.reconfigure(encoding='utf-8')

5.4. Bảng tổng hợp lịch sử Commit Git tiêu biểu theo các mốc tiến độ

Bảng 5.3: Bảng tổng hợp lịch sử Commit Git tiêu biểu theo các mốc tiến độ dự án

Mã Commit Hash	Thời gian commit	Tác giả commit	Module thay đổi	Nội dung thông điệp commit (Commit Message)
02bd2ea	2026-09-20	Đặng Duy Lợi	bigdata_dataset/	feat(dataset): collect and explore transfermarkt dataset (12 CSV tables)
e5e3989	2026-09-27	Đặng Duy Lợi	01_data_exploration	feat(hdfs): configure hadoop hdfs cluster and upload raw data lake
110cb57	2026-10-04	Đặng Duy Lợi	02_data_cleaning.py	feat(spark): implement pyspark etl data cleaning and feature engineering
7d2da9d	2026-10-10	Chu Văn Quốc Trung	03_spark_analysis.py	feat(analytics): add spark sql multi-dimensional queries and kmeans ml
d0be1d7	2026-10-12	Chu Văn Quốc	05_ml_regression.py	feat(ml): train

		Trung		random forest regressor model for player valuation
bb05d2a	2026-10-18	Nguyễn Thế Quang	06_kafka_producer.py	feat(kafka): setup kafka producer and consumer for real-time transfers
5283a93	2026-10-23	Nguyễn Thế Quang	airflow/dags/	feat(airflow): build airflow dag pipeline with 7 sequential tasks
1ea2ddc	2026-10-25	Nguyễn Thế Quang	08_dashboard_streamlit	feat(dashboard): develop streamlit dashboard with 14 interactive modules
5998888	2026-10-26	Đặng Duy Lợi	run_pipeline.py	fix(pipeline): optimize memory and enhance pagination and xai evaluation
d75e46f	2026-10-27	Đặng Duy Lợi	Bao_Cao/ & README	docs: complete final report and documentation with full traceability

5.5. Bảng phân công chi tiết và Tỷ lệ đóng góp của 3 thành viên

Bảng 5.4: Bảng phân công chi tiết và Tỷ lệ đóng góp của 3 thành viên

Họ và tên thành viên	Mã số sinh viên	Vai trò đảm nhiệm	Công việc và module phụ trách chính	Tỷ lệ đóng góp
Đặng Duy Lợi	2001230479	Nhóm trưởng	Kiến trúc hệ thống, hạ tầng	33.4%

			HDFS Data Lake, PySpark Data Cleaning & ETL (01, 02), điều phối pipeline, tổng hợp báo cáo	
Chu Văn Quốc Trung	2001231010	Thành viên	Xử lý tính toán Spark SQL phân tích đa chiều, Spark MLlib K-Means và Random Forest Regressor (03, 04, 05)	33.3%
Nguyễn Thế Quang	20012307010	Thành viên	Triển khai Apache Kafka streaming (06, 07), điều phối Apache Airflow DAG, xây dựng Web Dashboard Streamlit (08)	33.3%

5.6. Tuyên bố tuân thủ an toàn bảo mật thông tin

Toàn bộ mã nguồn, cấu hình Docker Compose và cơ sở dữ liệu đã được rà soát bảo mật nghiêm ngặt theo đúng yêu cầu đề tài. Dự án hoàn toàn không lưu trữ bất kỳ mật khẩu người dùng, API key, token bí mật hoặc thông tin nhạy cảm riêng tư nào.

CHƯƠNG 6: KẾT LUẬN VÀ KIẾN NGHỊ

6.1. Đánh giá kết quả đạt được

Đồ án đã hoàn thành xuất sắc mục tiêu đề ra với một hệ sinh thái Big Data toàn diện, tích hợp đầy đủ các công nghệ hàng đầu:

1. **Lưu trữ Data Lake:** Xây dựng Data Lake phân tán trên Hadoop HDFS lưu trữ an toàn 12 bảng dữ liệu (~870 MB).
2. **Xử lý phân tán PySpark:** Triển khai PySpark ETL làm sạch dữ liệu lớn và 4 truy vấn phân tích chuyên sâu bằng Spark SQL.
3. **Học máy phân tán Spark MLlib:** Ứng dụng Spark MLlib xây dựng thành công 2 mô hình học máy: K-Means (Silhouette = 0.6429) và Random Forest Regressor (R^2 = 84.68%).
4. **Streaming & Điều phối luồng:** Xử lý luồng sự kiện thời gian thực bằng Apache Kafka và tự động hóa toàn trình bằng Apache Airflow DAG 7 task tuần tự.
5. **Serving & Dashboard:** Phát triển Serving Data Mart và Web Dashboard Streamlit trực quan hóa tương tác chuẩn Enterprise.

6.2. Hạn chế của đề tài

Hệ thống hiện tại mới triển khai trên môi trường cụm máy tính đơn (Single-node cluster với nhiều container và tiến trình phân tán). Khi mở rộng lên cụm hàng chục node vật lý trong môi trường production, cần xem xét thêm bài toán cân bằng tải mạng và phân vùng dữ liệu động.

6.3. Kiến nghị và hướng nghiên cứu tiếp theo

Trong tương lai, đề tài có thể tiếp tục mở rộng theo các hướng sau:

1. **Streaming mở rộng:** Nâng cấp module Kafka Streaming sang Spark Structured Streaming để tính toán cửa sổ trượt (Sliding Window Aggregation) theo thời gian thực.

2. **Điều phối Container:** Đóng gói toàn bộ hệ thống (bao gồm cả Dashboard và Database) lên cụm điều phối container Kubernetes (K8s).
3. **Đồ thị tri thức & Deep Learning:** Ứng dụng mô hình học sâu đồ thị (Graph Neural Networks) để phân tích mạng lưới liên kết chiến thuật giữa các cầu thủ trên sân.

TÀI LIỆU THAM KHẢO

1. Apache Software Foundation (2024). Apache Hadoop 3.4.0 Documentation: HDFS Architecture Guide. Truy cập từ: https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html

2. Armbrust, M., Xin, R.S., Lian, C., Huai, Y., Liu, D.X., Bradley, J.K., Meng, X., Kaftan, T., Franklin, M.J., Ghodsi, A. and Zaharia, M. (2015). Spark SQL: Relational data processing in Spark. In Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data, pp. 1383-1394.

3. Beauchemin, M. (2015). Airflow: a workflow management platform. Airbnb Engineering & Data Science.

4. Chambers, B. and Zaharia, M. (2018). Spark: The Definitive Guide: Big Data Processing Made Simple. O'Reilly Media.

5. Karau, H., Konwinski, A., Wendell, P. and Zaharia, M. (2015). Learning Spark: Lightning-Fast Big Data Analysis. O'Reilly Media.

6. Kreps, J., Narkhede, N. and Rao, J. (2011). Kafka: A distributed messaging system for log processing. In Proceedings of the NetDB, pp. 1-7.

7. Transfermarkt GmbH & Co. KG (2024). Football Players Market Value Dataset. Kaggle Datasets. Truy cập từ: https://www.kaggle.com/datasets/davidcariboo/player-scores

8. Zaharia, M., Chowdhury, M., Franklin, M.J., Shenker, S. and Stoica, I. (2010). Spark: Cluster computing with working sets. In Proceedings of the 2nd USENIX Conference on Hot Topics in Cloud Computing (HotCloud 10), pp. 10-10.

PHỤ LỤC: HƯỚNG DẪN CÀI ĐẶT VÀ KHỞI CHẠY HỆ THỐNG

Nhóm sinh viên cung cấp kịch bản điều phối 1-click tự động hóa toàn bộ quá trình kiểm chứng đồ án trên máy tính:

- **Bước 1:** Cài đặt các gói thư viện Python cần thiết: pip install pyspark findspark kafka-python streamlit pandas pyarrow scikit-learn python-docx
- **Bước 2:** Thực thi toàn bộ chuỗi Pipeline Big Data bằng 1 lệnh duy nhất: python run_pipeline.py
- **Bước 3:** Khởi chạy Web Dashboard trực quan hóa tương tác: streamlit run 08_dashboard_streamlit.py (Truy cập tại http://localhost:8501)
- **Bước 4:** Khởi động cụm điều phối Airflow container: cd airflow && docker compose up -d (Truy cập tại http://localhost:8080)