BỘ CÔNG THƯƠNG — TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THỰC PHẨM TP. HCM (HUFI / HUIT)
KHOA CÔNG NGHỆ THÔNG TIN — HỌC PHẦN: CÔNG NGHỆ DỮ LIỆU LỚN (BIG DATA TECHNOLOGIES)

KỊCH BẢN CHI TIẾT TRÌNH DIỄN (LIVE DEMO) & BẢO VỆ HỆ THỐNG

"HỆ THỐNG PHÂN TÍCH DỮ LIỆU LỚN THỊ TRƯỜNG CHUYỂN NHƯỢNG BÓNG ĐÁ TRÊN NỀN TẢNG HADOOP HDFS, SPARK, KAFKA, AIRFLOW & STREAMLIT"

📌 THÔNG TIN HỒ SƠ BẢO VỆ

Giảng viên hướng dẫn: ThS. Huỳnh Thái Học

Nhóm sinh viên thực hiện (Nhóm 5): Đặng Duy Lợi (Trưởng nhóm - 2001230479) | Chu Văn Quốc Trung (2001231010) | Nguyễn Thế Quang (20012307010)

Thời lượng trình diễn khuyến nghị: 8 đến 10 phút (kèm 5 phút Q&A phản biện)

Liên kết GitHub Repository: https://github.com/takachi15/transfermarkt-bigdata-analytics

Môi trường Web Dashboard phục vụ demo: http://localhost:8501 (Khởi động 1-Click bằng tệp CHAY_WEB.bat)

1. Checklist chuẩn bị kỹ thuật trước giờ bảo vệ (3 phút trước khi lên bục)

Để buổi demo diễn ra trơn tru tuyệt đối, không gặp sự cố gián đoạn kết nối hay lỗi trình chiếu, nhóm sinh viên bắt buộc hoàn thành checklist 5 bước sau:

Hạng mục chuẩn bị	Thao tác kỹ thuật chi tiết	Trạng thái
Bước 1: Khởi động Web Dashboard	Nhấp đúp chuột vào CHAY_WEB.bat tại thư mục gốc. Trình duyệt tự động mở http://localhost:8501.	Sẵn sàng (Port 8501)
Bước 2: Mở chế độ Full Screen	Nhấn phím F11 trên trình duyệt Chrome/Edge để ẩn toàn bộ thanh URL và Bookmark, hiển thị chuẩn Enterprise.	Toàn màn hình chuyên nghiệp
Bước 3: Mở sẵn Tab phụ chứng minh	Mở sẵn 1 tab HDFS NameNode (cổng 9870) và 1 tab Airflow UI (cổng 8080) để chuyển tab tức thì khi thầy hỏi.	Tab 9870 & Tab 8080
Bước 4: Phân công vai trò	1 người ngồi máy tính điều khiển chuột mượt mà; 2 người đứng thuyết trình tự tin, rõ ràng, mắt hướng về Hội đồng.	3 thành viên phối hợp
Bước 5: Dự phòng Offline	Nếu mạng phòng học yếu, hệ thống vẫn chạy 100% hoàn hảo vì đã có sẵn SQLite Data Mart và Parquet cục bộ.	Chạy 100% độc lập

2. Khung thời gian phân bổ buổi thuyết trình (Tổng thời lượng: 8 - 10 phút)

Kịch bản được thiết kế theo cấu trúc kim tự tháp: Đi từ tổng quan kiến trúc Big Data đến điểm nhấn công nghệ cốt lõi và giá trị kinh tế thực tiễn:

Mốc thời gian	Phân đoạn nội dung trình bày	Trọng tâm nghiệp vụ & Công nghệ	Người nói
00:00 - 01:00	Phần 1: Mở đầu & Khởi chạy 1-Click	Giới thiệu đề tài, giảng viên hướng dẫn và kích hoạt hệ thống	Đặng Duy Lợi
01:00 - 02:30	Phần 2: Kiến trúc 5 tầng & Data Lake HDFS	Chứng minh Lambda Architecture, Data Lake 12 CSV (872 MB)	Đặng Duy Lợi
02:30 - 04:00	Phần 3: Benchmark hiệu năng Spark vs Pandas	Đo trực tiếp quét 3.18 triệu dòng: Spark 4.2 nhanh gấp 16.0 lần	Đặng Duy Lợi
04:00 - 05:30	Phần 4: Spark SQL & Bộ lọc Niên độ động	Phân tích 4 góc độ chuyên sâu, Year Drill-Down 2020-2025, URL paging	Chu Văn Quốc Trung
05:30 - 07:30	Phần 5: Điểm nhấn Machine Learning & Scouting	K-Means (k=3), Random Forest (R^2=84.7%) XAI & Săn cầu thủ hời	Chu Văn Quốc Trung
07:30 - 08:30	Phần 6: Kafka Streaming & Điều phối Airflow	Phát sóng luồng JSON cổng 9092 & Airflow DAG 7 tasks SUCCESS	Nguyễn Thế Quang
08:30 - 09:30	Phần 7: Serving Data Mart (SQLite) & Kết luận	Truy vấn CSDL Serving < 50ms, tổng kết kết quả đạt được	Nguyễn Thế Quang
09:30 - 15:00	Phần 8: Trả lời phản biện (Q&A)	Cả 3 thành viên giải đáp các câu hỏi chuyên sâu từ Hội đồng	Cả nhóm

3. Kịch bản chi tiết từng phân đoạn (Step-by-Step Live Demo Run-sheet)

Phân đoạn 1: Mở đầu & Khởi chạy hệ thống 1-Click (Thời lượng: 00:00 - 01:00 | Người nói: Đặng Duy Lợi)

🗣️ LỜI THOẠI THUYẾT TRÌNH MẪU: MỞ ĐẦU VÀ GIỚI THIỆU HỆ THỐNG

"Kính thưa Thầy Huỳnh Thái Học và Hội đồng đánh giá! Nhóm 5 chúng em xin phép được trình bày và bảo vệ đồ án môn học Công nghệ Dữ liệu lớn với đề tài: 'Xây dựng Data Pipeline thu thập, xử lý phân tán và phân tích dữ liệu thị trường chuyển nhượng bóng đá quốc tế'."

"Thị trường chuyển nhượng bóng đá toàn cầu có quy mô hàng chục tỷ Euro mỗi năm nhưng trước đây các thương vụ chủ yếu dựa trên cảm tính. Nhóm em đã giải quyết bài toán này bằng cách ứng dụng trọn vẹn hệ sinh thái Big Data: từ lưu trữ phân tán Hadoop HDFS, động cơ tính toán Apache Spark, xử lý luồng thời gian thực Apache Kafka, điều phối tự động Apache Airflow đến phục vụ trực quan hóa trên Web Dashboard Enterprise."

"Để chứng minh tính sẵn sàng và tính khả thi của hệ thống, toàn bộ chu trình đã được đóng gói 1-Click thông qua tệp CHAY_WEB.bat. Bây giờ em xin mời Thầy cùng bước vào giao diện thực tế của hệ thống!"

THAO TÁC TRÊN GIAO DIỆN (ACTION): HÀNH ĐỘNG THAO TÁC

1. Trên màn hình máy chiếu, chuyển mượt mà sang tab trình duyệt Chrome (F11) đang mở http://localhost:8501.
2. Chỉ tay vào Logo và Header của Dashboard: 'TRANSFERMARKT BIG DATA ANALYTICS PLATFORM'.

Phân đoạn 2: Kiến trúc 5 tầng & Khám phá Data Lake HDFS (Thời lượng: 01:00 - 02:30 | Người nói: Đặng Duy Lợi)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Trên Sidebar bên trái, nhấp chuột chọn trang: '2. Bản đồ ứng dụng Big Data'. Cuộn nhẹ để thấy sơ đồ 5 lớp công nghệ.
2. Tiếp tục nhấp chọn trang: '3. Khám phá HDFS Data Lake'.
3. Tại ô chọn bảng, nhấp dropdown chọn 'game_lineups.csv (3.18 Triệu dòng)' và 'players.csv (50k dòng)' để hiển thị Schema và 8 dòng bản ghi mẫu trực tiếp từ đĩa HDFS.

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Như Thầy đang thấy trên màn hình, đồ án của nhóm tuân thủ nghiêm ngặt mô hình kiến trúc Lambda Architecture phân thành 5 tầng rõ rệt: Tầng 1 Lưu trữ HDFS Data Lake, Tầng 2 Xử lý phân tán Spark, Tầng 3 Xử lý luồng Kafka, Tầng 4 Điều phối Airflow và Tầng 5 Serving Data Mart."

"Tại Tầng 1, kho dữ liệu Data Lake được lưu trữ phân tán trên HDFS tại thư mục /football_project/ gồm 12 bảng dữ liệu CSV với tổng cộng 7,497,433 bản ghi thô, dung lượng xấp xỉ 872.5 MB."

"Em xin trích xuất trực tiếp cấu trúc Schema của tệp game_lineups.csv gồm 3.18 triệu dòng và bảng trung tâm players.csv gồm 26 thuộc tính. Toàn bộ các thuộc tính từ ngày sinh, vị trí thi đấu, hợp đồng đến giá trị thị trường định giá đều được quản lý tập trung và phân tán trên cụm NameNode."

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN CÔNG NGHỆ CẦN NHỚ

- Quy mô dữ liệu: 12 bảng CSV, 7.497.433 dòng, 872.5 MB.
- URL lưu trữ: hdfs://localhost:9820/football_project/ (Đã có ảnh minh chứng cổng 9870 trong báo cáo).

Phân đoạn 3: Thực nghiệm Benchmark Hiệu năng Spark 4.2 vs Pandas (Thời lượng: 02:30 - 04:00 | Người nói: Đặng Duy Lợi)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Trên Sidebar, nhấp chọn trang: '4. Benchmark Hiệu năng (Spark vs Pandas)'.

2. Nhấp vào nút: 'Chạy kiểm tra tốc độ đọc 200,000 bản ghi' và đợi khoảng 1 giây để thanh loading hoàn thành và hiển thị kết quả đo đạc.

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Một câu hỏi phản biện rất lớn mà bất kỳ đề tài Big Data nào cũng phải đối mặt là: 'Dữ liệu này tại sao phải dùng Spark mà không dùng Pandas của Python cho đơn giản?'. Nhóm em đã giải đáp trực quan bằng mô-đun Benchmark thực nghiệm chạy trực tiếp ngay trên trang web."

"Khi chúng ta thực hiện quét 200,000 bản ghi của bảng game_lineups.csv, thư viện Pandas truyền thống bắt buộc phải xử lý tuần tự trên 1 core CPU duy nhất và tiêu tốn hơn 12.45 giây."

"Trong khi đó, Apache Spark 4.2 với động cơ tính toán tối ưu Tungsten và Catalyst Optimizer đã tự động chia nhỏ tập dữ liệu thành 16 partitions song song, khai thác tối đa 16 luồng CPU phần cứng, hoàn thành chỉ trong 0.78 giây — đạt tốc độ xử lý nhanh gấp 16.0 lần so với Pandas! Điều này khẳng định sự ưu việt không thể thay thế của kiến trúc tính toán phân tán Spark khi dữ liệu phình to lên hàng triệu dòng."

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN KỸ THUẬT

- Pandas: Chạy đơn luồng (Single Core), thời gian quét ~12.45s.
- Apache Spark 4.2: 16 partitions, 16 cores in-memory Tungsten, thời gian quét ~0.78s (Tăng tốc 16.0x lần).

Phân đoạn 4: Spark SQL & Bộ lọc Niên độ động (Thời lượng: 04:00 - 05:30 | Người nói: Chu Văn Quốc Trung)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Nhấp chọn trang: '1. Tổng quan & Thị trường'. Thao tác tích chọn / bỏ chọn checkbox 'Chỉ lấy niên độ gần nhất (2023 - Nay)', chỉ vào thẻ Live Feedback hiển thị '22,751 cầu thủ đang thi đấu'.
2. Nhấp chọn trang: '5. Phân tích Spark SQL'. Nhấp chuyển đổi giữa tab 'Biểu đồ trực quan' và 'Bảng dữ liệu chi tiết'. Bấm thử nút 'Tiếp ▶' trên thanh phân trang Enterprise.

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Em xin chào Thầy và Hội đồng, em là Quốc Trung, phụ trách phần phân tích dữ liệu Spark SQL và Machine Learning."

"Trước tiên, module 02_data_cleaning.py đã thực hiện làm sạch dữ liệu lớn: điền trung vị chiều cao, tính tuổi cầu thủ và loại bỏ các bản ghi khuyết giá trị định giá. Kết quả từ 50,149 dòng thô đã cô đọng thành 40,749 bản ghi sạch, lưu trữ dưới định dạng nén Parquet Snappy chỉ tốn 19.8 MB, tiết kiệm tới 97.7% dung lượng lưu trữ."

"Để dữ liệu không bị loãng bởi các cầu thủ đã giải nghệ từ 10 năm trước, nhóm thiết kế Bộ lọc niên độ động 2023 - Nay, tự động gom 22,751 hồ sơ cầu thủ đương đại với tổng định giá 16.48 tỷ Euro."

"Tiếp theo, module 03_spark_analysis.py đăng ký TempView để thực thi phân tán 4 câu truy vấn Spark SQL chuyên sâu: xác định Top 15 siêu sao đắt giá nhất, tương quan vị trí tiền đạo áp đảo giá trị, Top 10 quốc gia và độ tuổi vàng từ 24 - 28 tuổi. Đặc biệt, bảng dữ liệu được tích hợp bộ phân trang Enterprise thông minh và lưu trạng thái vào URL query params, giúp người dùng khi nhấn F5 refresh trình duyệt thì bảng vẫn giữ nguyên số trang đang xem mà không bị văng về đầu trang!"

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN KỸ THUẬT

- 50.149 bản ghi thô ➔ 40.749 bản ghi sạch (Tỷ lệ 81.27%).
- Định dạng Parquet Columnar nén Snappy: Giảm từ 872.5 MB xuống 19.8 MB (Tiết kiệm 97.7% đĩa cứng).
- 4 góc độ Spark SQL phân tán: Top 15, Vị trí thi đấu, Quốc gia, Độ tuổi.
- Phân trang URL query params: Giữ nguyên checkpoint trang khi F5 refresh.

Phân đoạn 5: Đỉnh cao Machine Learning (K-Means + Random Forest XAI + Scouting Engine) (Thời lượng: 05:30 - 07:30 | Người nói: Chu Văn Quốc Trung)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Nhấp chọn trang: '6. Phân cụm K-Means': Chỉ vào biểu đồ phân cụm 3 màu và bảng Silhouette Score k=3.
2. Nhấp chọn trang: '7. Dự đoán định giá (ML)':
   - Tab 1: Chọn cầu thủ mẫu 'Erling Haaland' (hoặc 'Kylian Mbappé', 'Lamine Yamal'). Quan sát thẻ dự đoán giá trị nhảy số ngay tức thì kèm Thẻ tag 'Đúng giá thị trường / Kèo hời'. Cuộn xuống thẻ XAI 5 bước giải trình và khoảng tin cậy 95%.
   - Tab 2: Chuyển sang tab 'Săn cầu thủ theo Ngân sách (Scouting Engine)'. Kéo thanh ngân sách về mức 35 triệu EUR, chọn Vị trí 'Attack', tích chọn 'Chỉ tìm cầu thủ Kèo hời (Undervalued)'. Xem danh sách cầu thủ hiển thị.

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Tiếp theo là phần cốt lõi tạo nên giá trị kinh tế của đề tài: Ứng dụng Machine Learning phân tán giải quyết bài toán định vị và định giá cầu thủ."

"Thứ nhất, mô hình học máy gom cụm Spark MLlib K-Means: Nhóm đã thực nghiệm Silhouette Analysis từ k=2 đến k=6 và xác định k=3 là tối ưu nhất với Silhouette Score đạt 0.6429. Mô hình chia cầu thủ thành 3 phân khúc chuẩn xác: Cụm 1 là Siêu sao thế giới (định giá trung bình 57 triệu EUR), Cụm 2 là Cầu thủ trụ cột các giải hàng đầu (12 triệu EUR) và Cụm 0 là Cầu thủ trẻ tiềm năng (1.2 triệu EUR)."

"Thứ hai, mô hình hồi quy Random Forest Regressor dự đoán giá trị chuyển nhượng: Do biến giá trị thị trường bị lệch phải rất lớn, nhóm đã áp dụng phép biến đổi logarit tự nhiên log1p(x) để chuẩn hóa, giúp mô hình đạt độ chính xác $R^2 = 84.68\%$ trên tập kiểm thử (Test 20%). Hệ thống tích hợp công nghệ suy luận thời gian thực (Real-time Inference) và Explainable AI (XAI) giải trình rõ 5 bước

cấu thành định giá cùng khoảng tin cậy 95%."

"Đặc biệt nhất, nhóm đã xây dựng tính năng 'Scouting Engine' phục vụ các chuyên gia tuyển trạch: Khi CLB nhập ngân sách 35 triệu Euro, mô hình Random Forest sẽ tự động quét đồng loạt tập dữ liệu để phát hiện các 'Kèo hời' (Undervalued) — tức những cầu thủ mà giá trị định giá thực tế của thuật toán cao hơn nhiều so với giá trị chuyển nhượng trên thị trường, giúp CLB tối ưu hóa hàng chục triệu Euro ngân sách chuyển nhượng!"

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI

- K-Means: k=3 tối ưu, Silhouette Score = 0.6429.
- Random Forest Regressor: R^2 = 84.68%, RMSE = 0.5942, MAE = 0.4120.
- Kỹ thuật toán học: Chuẩn hóa log1p(x) giải quyết triệt để độ lệch phải (Right-skewness).
- XAI & Scouting Engine: Giải trình suy luận 5 bước và phát hiện Kèo hời (Undervalued).

Phân đoạn 6: Kafka Streaming & Điều phối Airflow DAG (Thời lượng: 07:30 - 08:30 | Người nói: Nguyễn Thế Quang)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Nhấp chọn trang: '8. Giám sát Kafka Streaming': Xem các bản tin JSON giao dịch phát sóng thời gian thực, tổng số tiền chuyển nhượng nhảy số (> 700M EUR).
2. Nhấp chọn trang: '9. Giám sát Airflow DAG': Xem đồ thị 7 tasks tuần tự và trạng thái 100% SUCCESS. (Nếu thầy muốn xem thực tế, bấm chuyển sang tab Airflow UI cổng 8080).

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Em xin chào Thầy và Hội đồng, em là Thế Quang, phụ trách mảng Streaming Kafka, điều phối Airflow và Serving Data Mart."

"Bên cạnh việc xử lý mẻ dữ liệu lịch sử bằng Spark, trong các kỳ chuyển nhượng luôn có những thương vụ 'bom tấn' phát sinh đột xuất theo từng giờ. Để giải quyết tầng tốc độ Speed Layer, nhóm triển khai Apache Kafka tại cổng 9092 với topic 'football_transfers'. Module 06 Producer phát sóng liên tục các bản tin JSON thời gian thực, module 07 Consumer lắng nghe, bóc tách và nạp trực tiếp vào cơ sở dữ liệu với tổng giao dịch theo dõi vượt mốc 707 triệu Euro."

"Để toàn bộ Data Pipeline 7 bước hoạt động tự động và ổn định, nhóm xây dựng DAG transfermarkt_bigdata_pipeline trên nền tảng Apache Airflow 2.10 chạy qua cụm 5 container Docker Compose. Mỗi task từ nạp HDFS, chạy Spark ETL, phân tích SQL, huấn luyện ML đến nạp CSDL đều được kiểm tra điều kiện tiên quyết và ghi nhận trạng thái 100% SUCCESS!"

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN CÔNG NGHỆ

- Kafka Streaming: Topic football_transfers, port 9092, format JSON events, tổng giao dịch > 707M

EUR.

• Apache Airflow 2.10 DAG: 7 tasks tuần tự (wait_for_raw_data >> ingest_to_hdfs >> spark_etl_cleaning >> spark_sql_analytics >> train_ml_models >> kafka_streaming_pipeline >> export_to_datamart_db) đạt 100% SUCCESS.

Phân đoạn 7: Serving Data Mart (SQLite) & Kết luận (Thời lượng: 08:30 - 09:30 | Người nói: Nguyễn Thế Quang)

THAO TÁC TRÊN GIAO DIỆN (ACTION): THAO TÁC MÀN HÌNH

1. Nhấp chọn trang: '10. Cơ sở dữ liệu Data Mart'.
2. Tại dropdown truy vấn mẫu, chọn: 'Top 10 cầu thủ có giá trị cao nhất' và bấm chạy truy vấn. Bảng kết quả trả về tức thì < 10ms.

LỜI THOẠI THUYẾT TRÌNH MẪU: LỜI THOẠI THUYẾT TRÌNH

"Cuối cùng là Tầng phục vụ Serving Layer. Toàn bộ dữ liệu sạch sau tính toán phân tán được module load_to_database.py nạp vào CSDL Data Mart SQLite football_analytics.db gồm 5 bảng quan hệ được đánh chỉ mục tối ưu."

"Nhờ tầng Serving này, khi người dùng thao tác trên Dashboard, các câu lệnh SQL được phản hồi dưới 10 mili-giây, giúp trải nghiệm người dùng mượt mà tuyệt đối mà không cần phải gọi lại một Spark Job cồng kềnh tiêu tốn tài nguyên."

"Tổng kết lại, đồ án của nhóm 5 đã xây dựng thành công một giải pháp Big Data toàn diện từ thu thập, lưu trữ HDFS, xử lý phân tán Spark, streaming Kafka, điều phối Airflow đến trực quan hóa và khai thác thương mại Machine Learning. Toàn bộ mã nguồn và báo cáo đã được lưu trữ công khai trên GitHub. Nhóm chúng em xin chân thành cảm ơn Thầy Huỳnh Thái Học đã tận tình hướng dẫn trong suốt học phần! Chúng em xin phép được lắng nghe ý kiến đóng góp và câu hỏi phản biện từ Quý Thầy Cô!"

ĐIỂM KỸ THUẬT CẦN BẬT LÊN (KEY METRICS): ĐIỂM NHẤN CÔNG NGHỆ

• Serving Data Mart: football_analytics.db gồm 5 bảng (dim_players, fact_top15, fact_position, fact_country, fact_transfer_events).

• Độ trễ truy vấn: Dưới 10 mili-giây (< 10ms), giải phóng tải cho cụm Spark.

4. Bộ câu hỏi phản biện thường gặp của Hội đồng & Câu trả lời ăn điểm tuyệt đối (Top 5 Q&A Cheat Sheet)

Khi bước vào phần hỏi đáp (Q&A), các thầy cô trong Hội đồng thường xoay quanh 5 câu hỏi kinh điển về bản chất kỹ thuật Big Data. Dưới đây là câu trả lời mẫu sắc bén nhất:

Câu 1: Tại sao đề tài lại dùng thêm SQLite mà không cho Web Dashboard truy vấn trực tiếp từ Spark hoặc HDFS?

Thưa Thầy, đây là nguyên lý cốt lõi của kiến trúc phân tầng Lambda Architecture (Serving Layer). Hadoop HDFS và Spark được thiết kế cho Batch Layer nhằm tính toán xử lý dữ liệu quy mô lớn (hàng triệu bản ghi). Nếu mỗi lần người dùng click trên Web lại kích hoạt một Spark Job thì độ trễ sẽ mất từ 5 đến 30 giây để khởi tạo JVM và Driver, khiến ứng dụng web bị đơ. Do đó, Spark thực hiện tính toán trước (Pre-computing) và xuất dữ liệu sạch vào CSDL Serving Data Mart (SQLite / Relational DB) được đánh chỉ mục tối ưu, giúp Web phản hồi tức thì dưới 10ms mà không gây nghẽn tài nguyên cụm.

Câu 2: Dữ liệu 872 MB có thực sự cần đến Big Data (Hadoop/Spark) không hay chỉ cần Pandas là đủ?

Thưa Thầy, dữ liệu Transfermarkt của nhóm gồm 12 bảng với hơn 7.49 triệu bản ghi, trong đó bảng game_lineups.csv có gần 3.2 triệu dòng. Khi chạy benchmark thực tế trên cùng một máy tính, Pandas mất hơn 12.45 giây trên 1 core CPU, trong khi PySpark chia 16 phân vùng chạy song song trên 16 cores chỉ mất 0.78 giây (nhanh gấp 16 lần). Quan trọng hơn, kiến trúc này được thiết kế theo khả năng mở rộng ngang (Horizontal Scalability), nghĩa là khi bổ sung thêm dữ liệu các mùa giải mới lên 10 triệu hay 50 triệu dòng, hệ thống chỉ cần thêm DataNode mà không phải viết lại mã nguồn.

Câu 3: Tại sao nhóm lại chọn k=3 cho phân cụm K-Means mà không phải k=4 hay k=5?

Thưa Thầy, nhóm em chọn k=3 dựa trên cơ sở khoa học định lượng kết hợp với nghiệp vụ thực tế. Về mặt toán học, nhóm đã thực nghiệm phân tích Silhouette Score với k chạy từ 2 đến 6. Kết quả với k=3 đạt hệ số cao nhất là 0.6429, chứng tỏ các cụm có độ cô lập và gắn kết tối ưu nhất. Về mặt nghiệp vụ bóng đá, k=3 tương ứng hoàn hảo với 3 phân khúc thị trường: Siêu sao thế giới (World-Class Stars), Cầu thủ trụ cột giải VĐQG hàng đầu, và Cầu thủ trẻ tiềm năng / giải đấu phổ thông.

Câu 4: Tại sao biến giá trị thị trường lại phải biến đổi log1p(x) trong mô hình Random Forest?

Thưa Thầy, trong kinh tế bóng đá, phân phối giá trị cầu thủ bị lệch phải (Right-skewness) cực kỳ nặng nề: hơn 80% cầu thủ có giá dưới 5 triệu EUR, nhưng một số ít siêu sao có giá lên tới 180 - 200 triệu EUR. Nếu huấn luyện trực tiếp trên thang đo tuyến tính, hàm mất mát (MSE) sẽ bị các siêu sao chi phối hoàn toàn, dẫn đến mô hình dự đoán rất tệ ở nhóm cầu thủ phổ thông. Phép biến đổi log1p(y) = ln(1 + y) giúp nén thang đo về dạng gần phân phối chuẩn, giúp mô hình học cân bằng trên mọi phân khúc và nâng điểm R^2 từ dưới 60% lên đạt 84.68%.

Câu 5: Apache Kafka trong đề tài đóng vai trò gì và dữ liệu streaming đi về đâu?

Thưa Thầy, Apache Kafka đóng vai trò là Message Broker trong tầng xử lý luồng (Speed Layer). Dữ liệu lịch sử được Spark xử lý theo mẻ, nhưng thị trường chuyển nhượng liên tục có các thông tin giao dịch đột xuất (Breaking News). Khi đó, Producer phát sóng bản tin JSON qua topic football_transfers cổng 9092, Consumer lắng nghe, bóc tách và đẩy trực tiếp vào Serving Data Mart để cập nhật tức thì lên Dashboard, giúp người dùng nắm bắt dòng tiền thời gian thực mà không phải chạy lại toàn bộ mẻ dữ liệu lịch sử 872 MB.

5. Năm lời khuyên vàng để nhóm đạt điểm 10 tuyệt đối khi bảo vệ

• Mẹo 1: Tập trung vào tính năng thực tế, không đọc chữ trên màn hình: Hãy thao tác chuột liên tục theo nhịp điệu lời nói. Khi nói đến Spark, chuyển sang tab Benchmark; khi nói đến ML, chọn cầu thủ Haaland/Yamal để số liệu nhảy ngay lập tức.

• Mẹo 2: Nhấn mạnh từ khóa Big Data: Luôn nhắc đến các thuật ngữ kỹ thuật đắt giá: 16 partitions, In-memory Tungsten, Snappy Parquet, k=3 Silhouette 0.6429, log1p transformation, R^2 = 84.68%, Kafka topic 9092, Airflow DAG 7 tasks SUCCESS, Latency < 10ms.

• Mẹo 3: Sẵn sàng mở mã nguồn hoặc terminal nếu được yêu cầu: Nếu thầy cô yêu cầu kiểm tra code ngầm, bình tĩnh mở thư mục Source_Code/02_data_cleaning.py hoặc Source_Code/08_dashboard_streamlit.py để giải thích logic.

• Mẹo 4: Thái độ tự tin, khiêm tốn và lắng nghe: Luôn mở đầu câu trả lời bằng 'Dạ thưa Thầy...' và kết thúc bằng lời cảm ơn sự góp ý của Hội đồng.

• Mẹo 5: Bảo hiểm kỹ thuật: Toàn bộ dữ liệu và mô hình đã được nạp sẵn trong bigdata_dataset/football_analytics.db và rf_model.joblib, đảm bảo máy tính không cần kết nối Internet vẫn chạy trơn tru 100%!