TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HỒ CHÍ MINH (HUIT)
KHOA CÔNG NGHỆ THÔNG TIN — BỘ MÔN KHOA HỌC DỮ LIỆU

KỊCH BẢN CHI TIẾT TRÌNH DIỄN (LIVE DEMO) & BẢO VỆ ĐỒ ÁN BIG DATA

BẢNG CHỈ DẪN URL TRUY CẬP TỪNG PHÂN HỆ, THAO TÁC MÀN HÌNH VÀ LỜI THOẠI THUYẾT TRÌNH MẪU

[LƯU Ý] THÔNG TIN HỒ SƠ BẢO VỆ

Đề tài: Xây dựng Data Pipeline thu thập, xử lý phân tán và phân tích dữ liệu thị trường chuyển nhượng bóng đá quốc tế

Giảng viên hướng dẫn: ThS. Huỳnh Thái Học

Nhóm sinh viên thực hiện (Nhóm 5): Đặng Duy Lợi (Trưởng nhóm - 2001230479) | Chu Văn Quốc Trung (2001231010) | Nguyễn Thế Quang (20012307010)

Thời lượng khuyến nghị: 8 đến 10 phút trình diễn (kèm 5 phút Q&A phản biện)

GitHub Repository chính thức: https://github.com/takachi15/transfermarkt-bigdata-analytics

Địa chỉ Web Dashboard cục bộ: http://localhost:8501 (Khởi động 1-Click bằng file CHAY_WEB.bat)

1. Bảng phân công thời gian và Ánh xạ URL từng phân hệ (Navigation Matrix)

Bảng dưới đây giúp nhóm định vị tức thì Tab cần bấm trên Sidebar và URL tương ứng để chuyển đổi màn hình mượt mà trong 10 phút thuyết trình:

Phân đoạn & Thời gian	Tên Tab trên Sidebar	Địa chỉ URL tương ứng	Thành viên phụ trách
Phần 1: Mở đầu (00:00 - 01:00)	Trang bìa & Header	http://localhost:8501	**Đặng Duy Lợi**
Phần 2: Kiến trúc & HDFS (01:00 - 02:30)	Bản đồ ứng dụng Big Data Quản trị dữ liệu HDFS Data Lake	http://localhost:8501/?page=Bản+đồ+ứng+dụng+Big+Data http://localhost:8501/?page=Quản+trị+dữ+liệu+HDFS+Data+Lake	**Đặng Duy Lợi**
Phần 3: Benchmark Spark (02:30 - 04:00)	Benchmark hiệu năng Spark vs Pandas	http://localhost:8501/?page=Benchmark+hiệu+năng+Spark+vs+Pandas	**Đặng Duy Lợi**
Phần 4: Thị trường & SQL (04:00 - 05:30)	Tổng quan thị trường Phân tích Spark SQL	http://localhost:8501/?page=Tổng+quan+thị+trường http://localhost:8501/?page=Phân+tích+Spark+SQL	**Chu Văn Quốc Trung**
Phần 5: Machine Learning (05:30 - 07:30)	Phân cụm K-Means Dự đoán định giá (ML)	http://localhost:8501/?page=Phân+cụm+K-Means http://localhost:8501/?page=Dự+đoán+định+giá+(ML)	**Chu Văn Quốc Trung**
Phần 6: Kafka & Airflow (07:30 - 08:30)	Dòng dữ liệu Kafka Streaming Điều phối Airflow Workflow	http://localhost:8501/?page=Dòng+dữ+liệu+Kafka+Streaming http://localhost:8501/?page=Điều+phối+Airflow+Workflow	**Nguyễn Thế Quang**
Phần 7: Data Mart & Tổng kết (08:30 - 09:30)	Truy vấn CSDL Data Mart	http://localhost:8501/?page=Truy+vấn+CSDL+Data+Mart	**Nguyễn Thế Quang**

Phần 8: Q&A Phản biện (09:30 - 15:00)	Toàn bộ Dashboard & Terminal	Sẵn sàng các cổng 8501, 9870, 8080	**Cả 3 thành viên**

2. Kịch bản chi tiết từng phân đoạn (Step-by-Step Live Demo Run-sheet)

Phần 1: Mở đầu & Khởi chạy hệ thống 1-Click (Thời lượng: 00:00 - 01:00 | Người nói: Đặng Duy Lợi)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]
- **Tên Tab trên Sidebar:** **"Trang bìa Web Dashboard"**
- **URL Web Dashboard:** `http://localhost:8501`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Trên màn hình máy chiếu, mở trình duyệt Chrome/Edge đang chạy URL: http://localhost:8501.
2. Nhấn phím F11 để bật chế độ Toàn màn hình (Full Screen), ẩn thanh URL để hiển thị chuyên nghiệp.
3. Chỉ tay vào Header chính: 'HỆ THỐNG PHÂN TÍCH DỮ LIỆU LỚN THỊ TRƯỜNG BÓNG ĐÁ' và 4 badge trạng thái xanh (HDFS: 872.5 MB, Spark 4.2 Engine, Kafka Port 9092, Airflow 7 Tasks OK).

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Kính thưa Thầy Huỳnh Thái Học và Hội đồng đánh giá! Nhóm 5 chúng em xin phép được trình bày và bảo vệ đồ án môn học Công nghệ Dữ liệu lớn với đề tài: 'Xây dựng Data Pipeline thu thập, xử lý phân tán và phân tích dữ liệu thị trường chuyển nhượng bóng đá quốc tế'."

"Thị trường chuyển nhượng bóng đá toàn cầu có quy mô hàng chục tỷ Euro mỗi năm nhưng trước đây chủ yếu dựa trên cảm tính. Nhóm em đã giải quyết bài toán này bằng cách ứng dụng trọn vẹn kiến trúc Big Data phân tán: từ lưu trữ HDFS Data Lake, xử lý phân tán Apache Spark, truyền tải thời gian thực Apache Kafka, điều phối tự động Apache Airflow đến phục vụ trực quan hóa trên Web Dashboard Enterprise."

"Toàn bộ hệ sinh thái đã được đóng gói 1-Click tự động hóa qua tệp CHAY_WEB.bat. Bây giờ em xin mời Thầy cùng bước vào từng phân hệ kỹ thuật của hệ thống!"

Phần 2: Kiến trúc Lambda 5 lớp & Khám phá HDFS Data Lake (Thời lượng: 01:00 - 02:30 | Người nói: Đặng Duy Lợi)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]
- **Tên Tab trên Sidebar:** **"Bản đồ ứng dụng Big Data & Quản trị dữ liệu HDFS Data Lake"**
- **URL Web Dashboard:** `http://localhost:8501/?page=Bản+đồ+ứng+dụng+Big+Data`
- **Cổng dịch vụ hạ tầng liên kết:** `http://localhost:8501/?page=Quản+trị+dữ+liệu+HDFS+Data+Lake (HDFS Web UI: http://localhost:9870)`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Trên Sidebar bên trái, click chọn menu: 'Bản đồ ứng dụng Big Data'. Cuộn nhẹ để Hội đồng nhìn thấy ma trận 5 tầng công nghệ.

2. Tiếp tục click chọn menu: 'Quản trị dữ liệu HDFS Data Lake'.

3. Tại ô dropdown chọn bảng, lần lượt chọn 'game_lineups.csv (3.18 Triệu dòng)' và 'players.csv (50,149 dòng)' để màn hình hiển thị trực tiếp Schema 26 cột và 8 dòng dữ liệu mẫu trích xuất từ đĩa HDFS.

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Thưa Thầy, đồ án của nhóm được thiết kế chặt chẽ theo mô hình Lambda Architecture gồm 5 lớp phân tách: Tầng 1 Lưu trữ HDFS Data Lake, Tầng 2 Xử lý phân tán Spark, Tầng 3 Xử lý luồng Kafka, Tầng 4 Điều phối Airflow và Tầng 5 Serving Data Mart."

"Tại Tầng 1, kho dữ liệu thô được nạp lên Hadoop HDFS tại thư mục phân tán /football_project/ gồm trọn vẹn 12 bảng CSV với hơn 7.49 triệu bản ghi, dung lượng xấp xỉ 872.5 MB, cấu hình Replication factor = 3 và Block size 128MB."

"Em xin trích xuất trực tiếp cấu trúc của bảng game_lineups.csv gồm gần 3.2 triệu dòng và bảng trung tâm players.csv gồm 26 thuộc tính. Toàn bộ dữ liệu đều được quản lý phân tán và sẵn sàng cấp phát cho tầng tính toán phía sau."

[ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI] ĐIỂM NHẤN CÔNG NGHỆ CẦN NÓI

• Quy mô dữ liệu: 12 bảng CSV, 7.497.433 bản ghi thô, 872.5 MB.

• URL HDFS: hdfs://localhost:9820/football_project/ (Replication = 3, dung lượng vật lý 2.58 GB).

Phần 3: Benchmark Thực nghiệm Hiệu năng Spark 4.2 vs Pandas (Thời lượng: 02:30 - 04:00 | Người nói: Đặng Duy Lợi)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]

• **Tên Tab trên Sidebar: "Benchmark hiệu năng Spark vs Pandas"**

• **URL Web Dashboard:** `http://localhost:8501/?page=Benchmark+hiệu+năng+Spark+vs+Pandas`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Trên Sidebar, click chọn menu: 'Benchmark hiệu năng Spark vs Pandas'.

2. Nhấp chuột vào nút: 'Chạy kiểm tra tốc độ đọc 200,000 bản ghi'.

3. Đợi 1 giây để thanh tiến trình hoàn thành và biểu đồ so sánh cột thời gian hiển thị.

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Một câu hỏi lớn mà Hội đồng thường đặt ra là: 'Tập dữ liệu này tại sao phải dùng Hadoop/Spark mà không dùng Pandas cho tiện?'. Nhóm em xin trả lời bằng mô-đun Benchmark đo đạc thực nghiệm trực tiếp ngay trên hệ thống."

"Khi thực hiện thao tác quét và tính toán trên 200,000 bản ghi của bảng game_lineups.csv, thư viện Pandas truyền thống bắt buộc phải xử lý tuần tự trên 1 core CPU duy nhất và tiêu tốn hơn 12.45 giây."

"Trong khi đó, Apache Spark 4.2 với động cơ tối ưu Tungsten và Catalyst Optimizer đã tự động chia nhỏ dữ liệu thành 16 partitions song song, tận dụng 16 luồng CPU phần cứng, hoàn thành chỉ trong 0.78 giây — đạt tốc độ xử lý nhanh gấp 16.0 lần so với Pandas! Điều này khẳng định năng lực mở rộng ngang (Horizontal Scalability) không thể thay thế của Spark khi dữ liệu tăng lên hàng chục triệu bản ghi."

[ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI] ĐIỂM NHẤN CÔNG NGHỆ CẦN NÓI

• Pandas: Đơn luồng (Single Core), thời gian xử lý: ~12.45 giây.

• Apache Spark 4.2: 16 partitions song song, thời gian xử lý: ~0.78 giây (Tốc độ nhanh gấp 16.0 lần).

Phần 4: PySpark ETL, Bộ lọc Niên độ & Spark SQL (Thời lượng: 04:00 - 05:30 | Người nói: Chu Văn Quốc Trung)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]

• **Tên Tab trên Sidebar:** **"Tổng quan thị trường & Phân tích Spark SQL"**

• **URL Web Dashboard:** `http://localhost:8501/?page=Tổng+quan+thị+trường`

• **Cổng dịch vụ hạ tầng liên kết:** `http://localhost:8501/?page=Phân+tích+Spark+SQL`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Click chọn menu: 'Tổng quan thị trường'. Thao tác tích chọn / bỏ chọn checkbox 'Chỉ lấy niên độ gần nhất (2023 - Nay)', chỉ tay vào thẻ thống kê hiển thị: 22,751 cầu thủ đang thi đấu với tổng định giá 16.48 tỷ Euro.

2. Click chọn menu: 'Phân tích Spark SQL'. Chuyển đổi giữa 4 tab phân tích: Top 15 siêu sao, Vị trí thi đấu, Top 10 quốc gia và Độ tuổi vàng. Bấm thử nút 'Trang tiếp ▶' trên thanh phân trang Enterprise.

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Em xin chào Thầy và Hội đồng, em là Chu Văn Quốc Trung, phụ trách phần PySpark ETL, Spark SQL và Machine Learning."

"Module 02_data_cleaning.py đã thực hiện làm sạch dữ liệu lớn: điền trung vị chiều cao, tính tuổi chuẩn xác từ ngày sinh và loại bỏ các bản ghi khuyết định giá. Kết quả từ 50,149 dòng thô đã được tinh lọc thành 40,749 bản ghi sạch, lưu trữ dưới định dạng nén Parquet Snappy chỉ tốn 1.41 MB, tiết kiệm tới 97.7% dung lượng lưu trữ."

"Để dữ liệu không bị loãng bởi các cầu thủ đã giải nghệ từ hàng chục năm trước, nhóm thiết kế Bộ lọc niên độ động 2023 - Nay, tự động gom 22,751 hồ sơ cầu thủ đương đại."

"Tại module 03_spark_analysis.py, nhóm đăng ký TempView để thực thi phân tán 4 truy vấn Spark SQL chuyên sâu: xác định Top 15 siêu sao đắt giá nhất (Haaland, Bellingham, Mbappe: 180M - 200M Euro), tương quan vị trí tiền đạo áp đảo giá trị, Top 10 quốc gia và độ tuổi vàng từ 25 - 28 tuổi. Đặc biệt, bảng dữ liệu được tích hợp bộ phân trang Enterprise thông minh đồng bộ trạng thái vào URL query params, giúp người dùng khi nhấn F5 refresh trình duyệt thì bảng vẫn giữ nguyên số trang đang xem!"

[ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI] ĐIỂM NHẤN CÔNG NGHỆ CẦN NÓI

• PySpark ETL: 50.149 bản ghi thô -> 40.749 bản ghi sạch (Tỷ lệ 81.25%).

• Tối ưu Parquet Snappy: Giảm dung lượng đĩa từ 872.5 MB xuống 1.41 MB.

• Spark SQL: 4 góc độ đa chiều, phân trang Enterprise checkpoint URL query param.

Phần 5: Đỉnh cao Machine Learning & Săn cầu thủ theo Ngân sách (Thời lượng: 05:30 - 07:30 | Người nói: Chu Văn Quốc Trung)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]

• **Tên Tab trên Sidebar:** **"Phân cụm K-Means & Dự đoán định giá (ML)"**
• **URL Web Dashboard:** `http://localhost:8501/?page=Phân+cụm+K-Means`
• **Cổng dịch vụ hạ tầng liên kết:** `http://localhost:8501/?page=Dự+đoán+định+giá+(ML)`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Click chọn menu: 'Phân cụm K-Means': Chỉ vào biểu đồ phân cụm 3 màu và bảng Silhouette Score k=3 đạt 0.6429.

2. Click chọn menu: 'Dự đoán định giá (ML)':

- Tại ô chọn cầu thủ, gõ tên 'Erling Haaland' (hoặc 'Lamine Yamal', 'Kylian Mbappé'). Quan sát kết quả định giá AI nhảy ra tức thì kèm Thẻ trạng thái 'Đúng giá / Kèo hời'. Cuộn chuột chỉ vào 5 bước giải trình Explainable AI (XAI) và khoảng tin cậy 95%.

- Cuộn xuống phân hệ 'Săn cầu thủ theo Ngân sách (Scouting Engine)': Kéo thanh ngân sách về mức 35 triệu EUR, chọn Vị trí 'Attack', tích chọn 'Chỉ tìm cầu thủ Kèo hời (Undervalued)'. Xem danh sách các viên ngọc quý được AI phát hiện.

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Tiếp theo là phần cốt lõi tạo nên giá trị kinh tế của đồ án: Ứng dụng Machine Learning phân tán giải quyết bài toán phân đoạn và định giá cầu thủ."

"Thứ nhất, phân cụm Spark MLlib K-Means: Nhóm đã thực nghiệm Silhouette Analysis từ k=2 đến k=6 và xác định k=3 là tối ưu nhất với Silhouette Score đạt 0.6429. Mô hình chia cầu thủ thành 3 phân khúc chuẩn xác: Cụm 0 là Siêu sao thế giới (định giá trung bình 29.7 triệu EUR), Cụm 1 là Cầu thủ trụ cột các giải hàng đầu (1.2 triệu EUR) và Cụm 2 là Cầu thủ tiềm năng/phổ thông (0.4 triệu EUR)."

"Thứ hai, mô hình Random Forest Regressor dự đoán giá trị chuyển nhượng: Do biến giá trị thị trường bị lệch phải nặng nề, nhóm áp dụng phép biến đổi logarit chuẩn hóa y = ln(1 + market_value), giúp mô hình đạt độ chính xác R2 = 84.68% trên tập kiểm thử Test 20%. Hệ thống tích hợp Explainable AI (XAI) giải trình rõ 5 nhân tố cấu thành định giá cùng khoảng tin cậy 95%."

"Đặc biệt nhất, nhóm đã xây dựng tính năng 'Scouting Engine' phục vụ các chuyên gia tuyển trạch: Khi CLB nhập ngân sách 35 triệu Euro, mô hình Random Forest sẽ tự động quét đồng loạt toàn bộ 40,749 hồ sơ để phát hiện các 'Kèo hời' (Undervalued) — tức những cầu thủ mà giá trị thuật toán dự đoán cao hơn nhiều so với giá trị niêm yết trên thị trường, giúp CLB tiết kiệm hàng chục triệu Euro ngân sách chuyển nhượng!"

[ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI] ĐIỂM NHẤN CÔNG NGHỆ CẦN NÓI

• K-Means: k=3 tối ưu, Silhouette Score = 0.6429.
• Random Forest Regressor: R2 = 84.68%, RMSE = 0.5942, MAE = 0.4120, file rf_model.joblib.
• Kỹ thuật toán học: Chuẩn hóa log1p(y) triệt tiêu độ lệch phải (Right-skewness).
• XAI & Scouting Engine: Giải trình suy luận 5 bước và phát hiện Kèo hời (Undervalued).

Phần 6: Kafka Streaming & Điều phối Airflow DAG (Thời lượng: 07:30 - 08:30 | Người nói: Nguyễn Thế Quang)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]
• **Tên Tab trên Sidebar:** **"Dòng dữ liệu Kafka Streaming & Điều phối Airflow Workflow"**
• **URL Web Dashboard:** `http://localhost:8501/?page=Dòng+dữ+liệu+Kafka+Streaming`
• **Cổng dịch vụ hạ tầng liên kết:** `http://localhost:8501/?page=Điều+phối+Airflow+Workflow (Airflow`

UI: http://localhost:8080)

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Click chọn menu: 'Dòng dữ liệu Kafka Streaming': Xem bảng tin JSON giao dịch phát sóng thời gian thực, tổng số tiền chuyển nhượng nhảy số (15 thương vụ, EUR 707M).

2. Click chọn menu: 'Điều phối Airflow Workflow': Chỉ vào đồ thị 7 tasks tuần tự và trạng thái 100% SUCCESS. (Nếu Thầy yêu cầu mở cụm container thật, chuyển sang tab trình duyệt cổng 8080).

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Em xin chào Thầy và Hội đồng, em là Nguyễn Thế Quang, phụ trách mảng Streaming Kafka, điều phối Airflow và Serving Data Mart."

"Bên cạnh việc xử lý mẻ dữ liệu lịch sử bằng Spark, trong các kỳ chuyển nhượng luôn có những thương vụ đột xuất theo từng giờ. Để giải quyết tầng tốc độ Speed Layer, nhóm triển khai Apache Kafka tại cổng 9092 với topic 'football_transfers'. Module 06 Producer phát sóng liên tục các bản tin JSON thời gian thực, module 07 Consumer lắng nghe, bóc tách và nạp trực tiếp vào CSDL với tổng giá trị giao dịch theo dõi vượt mốc 707 triệu Euro."

"Để toàn bộ Data Pipeline 7 bước hoạt động tự động và ổn định, nhóm xây dựng DAG transfermarkt_bigdata_pipeline trên nền tảng Apache Airflow 2.10 chạy qua cụm 5 container Docker Compose. Mỗi task từ nạp HDFS, chạy Spark ETL, phân tích SQL, huấn luyện ML đến nạp CSDL đều được kiểm tra điều kiện tiên quyết và ghi nhận trạng thái 100% SUCCESS trong thời gian 2 phút 10 giây!"

[ĐIỂM NHẤN CÔNG NGHỆ BẮT BUỘC NÓI] ĐIỂM NHẤN CÔNG NGHỆ CẦN NÓI

• Kafka Streaming: Topic football_transfers, port 9092, format JSON, tổng giá trị > 707M EUR.

• Apache Airflow 2.10 DAG: 7 tasks tuần tự đạt 100% SUCCESS (wait_for_raw_data >> ingest_to_hdfs >> spark_etl >> spark_sql >> train_ml >> kafka >> export_db).

Phần 7: Serving Data Mart (SQLite) & Kết luận (Thời lượng: 08:30 - 09:30 | Người nói: Nguyễn Thế Quang)

[ĐỊA CHỈ TRUY CẬP VÀ PHÂN HỆ GIAO DIỆN]

• **Tên Tab trên Sidebar:** **"Truy vấn CSDL Data Mart"**

• **URL Web Dashboard:** `http://localhost:8501/?page=Truy+vấn+CSDL+Data+Mart`

[THAO TÁC MÀN HÌNH & CHUỘT] HÀNH ĐỘNG THAO TÁC MÀN HÌNH

1. Click chọn menu: 'Truy vấn CSDL Data Mart'.

2. Tại ô dropdown chọn câu truy vấn mẫu, chọn: 'Top 10 cầu thủ có giá trị cao nhất' và bấm nút 'Thực thi truy vấn SQL'. Bảng kết quả trả về tức thì dưới 10ms.

[LỜI THOẠI THUYẾT TRÌNH MẪU] LỜI THOẠI THUYẾT TRÌNH MẪU

"Cuối cùng là Tầng phục vụ Serving Layer. Toàn bộ dữ liệu sạch sau tính toán phân tán được module load_to_database.py nạp vào CSDL Data Mart SQLite football_analytics.db gồm 5 bảng quan hệ được đánh chỉ

mục tối ưu, giúp Web phản hồi tức thì dưới 10ms mà không gây nghẽn tài nguyên cụm Spark."

"Tóm lại, đồ án của Nhóm 5 đã vận dụng đầy đủ và xuất sắc 5 trụ cột công nghệ Big Data: Hadoop HDFS, Apache Spark, Apache Kafka, Apache Airflow và Machine Learning. Hệ thống hoạt động trơn tru 100%, có khả năng tái hiện hoàn toàn và mang lại giá trị ứng dụng thực tiễn cao."

"Nhóm em xin chân thành cảm ơn Thầy Huỳnh Thái Học và Hội đồng đã chú ý lắng nghe. Chúng em xin sẵn sàng bước vào phần trả lời câu hỏi phản biện của Thầy Cô!"

3. Bộ câu hỏi phản biện thường gặp của Hội đồng & Câu trả lời ăn điểm tuyệt đối (Top 5 Q&A)

Câu 1: Tại sao đề tài lại dùng thêm SQLite mà không cho Web Dashboard truy vấn trực tiếp từ Spark hoặc HDFS?

Thưa Thầy, đây là nguyên lý cốt lõi của kiến trúc phân tầng Lambda Architecture (Serving Layer). Hadoop HDFS và Spark được thiết kế cho Batch Layer nhằm tính toán xử lý dữ liệu quy mô lớn (hàng triệu bản ghi). Nếu mỗi lần người dùng click trên Web lại kích hoạt một Spark Job thì độ trễ sẽ mất từ 5 đến 30 giây để khởi tạo JVM và Driver, khiến ứng dụng web bị đơ. Do đó, Spark thực hiện tính toán trước (Pre-computing) và xuất dữ liệu sạch vào CSDL Serving Data Mart (SQLite) được đánh chỉ mục tối ưu, giúp Web phản hồi tức thì dưới 10ms mà không gây nghẽn tài nguyên cụm.

Câu 2: Dữ liệu 872 MB có thực sự cần đến Big Data (Hadoop/Spark) không hay chỉ cần Pandas là đủ?

Thưa Thầy, dữ liệu Transfermarkt của nhóm gồm 12 bảng với hơn 7.49 triệu bản ghi, trong đó bảng game_lineups.csv có gần 3.2 triệu dòng. Khi chạy benchmark thực tế trên cùng một máy tính, Pandas mất hơn 12.45 giây trên 1 core CPU, trong khi PySpark chia 16 phân vùng chạy song song trên 16 cores chỉ mất 0.78 giây (nhanh gấp 16 lần). Quan trọng hơn, kiến trúc này được thiết kế theo khả năng mở rộng ngang (Horizontal Scalability), nghĩa là khi bổ sung thêm dữ liệu các mùa giải mới lên 10 triệu hay 50 triệu dòng, hệ thống chỉ cần thêm DataNode mà không phải viết lại mã nguồn.

Câu 3: Tại sao nhóm lại chọn k=3 cho phân cụm K-Means mà không phải k=4 hay k=5?

Thưa Thầy, nhóm em chọn k=3 dựa trên cơ sở khoa học định lượng kết hợp với nghiệp vụ thực tế. Về mặt toán học, nhóm đã thực nghiệm phân tích Silhouette Score với k chạy từ 2 đến 6. Kết quả với k=3 đạt hệ số cao nhất là 0.6429, chứng tỏ các cụm có độ cô lập và gắn kết tối ưu nhất. Về mặt nghiệp vụ bóng đá, k=3 tương ứng hoàn hảo với 3 phân khúc thị trường: Siêu sao thế giới (World-Class Stars), Cầu thủ trụ cột giải VĐQG hàng đầu, và Cầu thủ trẻ tiềm năng / giải đấu phổ thông.

Câu 4: Tại sao biến giá trị thị trường lại phải biến đổi log1p(y) trong mô hình Random Forest?

Thưa Thầy, trong kinh tế bóng đá, phân phối giá trị cầu thủ bị lệch phải (Right-skewness) cực kỳ nặng nề: hơn 80% cầu thủ có giá dưới 5 triệu EUR, nhưng một số ít siêu sao có giá lên tới 180 - 200 triệu EUR. Nếu huấn luyện trực tiếp trên thang đo tuyến tính, hàm mất mát (MSE) sẽ bị các siêu sao chi phối hoàn toàn, dẫn đến mô hình dự đoán rất tệ ở nhóm cầu thủ phổ thông. Phép biến đổi log1p(y) = ln(1 + y) giúp nén thang đo về dạng gần phân phối chuẩn, giúp mô hình học cân bằng trên mọi phân khúc và nâng điểm R2 từ dưới 60% lên đạt 84.68%.

Câu 5: Apache Kafka trong đề tài đóng vai trò gì và dữ liệu streaming đi về đâu?

Thưa Thầy, Apache Kafka đóng vai trò là Message Broker trong tầng xử lý luồng (Speed Layer). Dữ liệu lịch sử được Spark xử lý theo mẻ, nhưng thị trường chuyển nhượng liên tục có các thông tin giao dịch đột xuất (Breaking News). Khi đó, Producer phát sóng bản tin JSON qua topic football_transfers cổng 9092, Consumer lắng nghe, bóc tách và đẩy trực tiếp vào Serving Data Mart để cập nhật tức thì lên Dashboard, giúp người dùng nắm bắt dòng tiền thời gian thực mà không phải chạy lại toàn bộ mẻ dữ liệu lịch sử 872 MB.

4. Năm lời khuyên vàng để nhóm đạt điểm 10 tuyệt đối khi bảo vệ

• Lời khuyên 1: Thao tác chuột nhịp nhàng theo lời nói: Người ngồi máy tính chuyển tab trước 3 giây khi người thuyết trình bắt đầu nói về phân hệ đó. Khi nói đến Spark, chuyển sang Benchmark; khi nói đến ML, chọn cầu thủ Haaland/Yamal để số liệu nhảy ngay lập tức.

• Lời khuyên 2: Nhấn mạnh từ khóa Big Data đắt giá: 16 partitions parallel, In-memory Tungsten, Snappy Parquet, k=3 Silhouette 0.6429, log1p transformation, R2 = 84.68%, Kafka topic 9092, Airflow DAG 7 tasks SUCCESS, Latency < 10ms.

• Lời khuyên 3: Sẵn sàng mở mã nguồn hoặc terminal nếu Thầy yêu cầu: Bình tĩnh mở thư mục Source_Code/02_data_cleaning.py hoặc Source_Code/08_dashboard_streamlit.py để chỉ vào hàm xử lý.

• Lời khuyên 4: Thái độ tự tin, khiêm tốn và tôn trọng: Luôn mở đầu câu trả lời bằng 'Dạ thưa Thầy...' và kết thúc bằng lời cảm ơn sự góp ý của Hội đồng.

• Lời khuyên 5: Bảo hiểm kỹ thuật an toàn 100%: Dữ liệu và mô hình đã lưu sẵn trong football_analytics.db và rf_model.joblib, đảm bảo máy tính không cần Internet vẫn chạy mượt mà 100%!